

# Analyse des OpenPGP Web of Trust

Studienarbeit  
von

**Alexander Ulrich**

Lehrstuhl für Rechnernetze und Internet  
Wilhelm-Schickard-Institut für Informatik  
Fakultät für Informations- und Kognitionswissenschaften  
Universität Tübingen

Erstgutachter: Prof. Dr. Peter Hauck  
Betreuer Mitarbeiter: Dipl.-Inform. Ralph Holz

Bearbeitungszeit: 08. Monat 2009 – 01. Monat 2010



---

Ich erkläre hiermit, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe.

Tübingen, den ???. ?????? 200?



# Inhaltsverzeichnis

<b>1</b>	<b>Grundlagen</b>	<b>1</b>
1.1	Kryptographie mit öffentlichen Schlüsseln . . . . .	1
1.1.1	Prinzip . . . . .	1
1.1.2	Authentisierung von Schlüsseln . . . . .	1
1.1.2.1	Zentrale PKI . . . . .	1
1.1.2.2	Web of Trust . . . . .	1
1.2	PGP/GnuPG . . . . .	1
1.2.1	Geschichte von PGP und GnuPG . . . . .	1
1.2.2	Eigenschaften/Fähigkeiten der Implementierungen . . . . .	1
1.2.3	Das GnuPG-Vertrauensmodell . . . . .	1
1.2.4	Soziale Komponente des Web of Trust . . . . .	3
1.3	Der OpenPGP-Standard (RFC4880) . . . . .	3
1.3.1	Paketformat v4 . . . . .	3
1.3.2	Unterschiede v3 . . . . .	3
1.4	Graphentheorie allgemein . . . . .	3
1.5	Netzwerkanalyse . . . . .	3
1.5.1	Netzwerkstatistiken . . . . .	3
1.5.2	Communities . . . . .	3
1.6	Verwandte Arbeiten . . . . .	4
1.6.1	Analysen des OpenPGP-Web of Trust . . . . .	4
1.6.2	Community-Strukturen allgemein . . . . .	4
<b>2</b>	<b>Methoden und Materialien</b>	<b>5</b>
2.1	Warum eigene Software? . . . . .	5
2.2	Design und Implementierung . . . . .	7
2.2.1	Der SKS Keyserver . . . . .	7
2.2.2	Eigene Software . . . . .	7
2.2.2.1	Datenextraktion . . . . .	8
2.2.2.2	Datenauswertung . . . . .	10
2.3	Community-Analyse . . . . .	11
2.3.1	Communities in gerichteten Graphen . . . . .	14
<b>3</b>	<b>Ergebnisse und Diskussion</b>	<b>15</b>
3.1	Allgemeine Merkmale des Netzwerkes . . . . .	15
3.2	Eigenschaften einzelner Schlüssel . . . . .	15
3.3	Zusammenhangskomponenten und Communities . . . . .	15
3.4	Struktur der starken Zusammenhangskomponenten . . . . .	15
3.4.1	Communities . . . . .	15



# 1. Grundlagen

## 1.1 Kryptographie mit öffentlichen Schlüsseln

### 1.1.1 Prinzip

Klassische Kryptographie basiert auf einem *Geheimnis* oder *privaten Schlüssel*, der beiden Kommunikationspartnern bekannt ist.

### 1.1.2 Authentisierung von Schlüsseln

#### 1.1.2.1 Zentrale PKI

#### 1.1.2.2 Web of Trust

## 1.2 PGP/GnuPG

### 1.2.1 Geschichte von PGP und GnuPG

### 1.2.2 Eigenschaften/Fähigkeiten der Implementierungen

### 1.2.3 Das GnuPG-Vertrauensmodell

Öffentliche PGP-Schlüssel werden oft nicht in einer Weise übergeben, die die sofortige Verifikation des Schlüssels zulässt, beispielsweise bei einem persönlichen Treffen. Stattdessen werden Schlüssel häufig per E-Mail, über einen Keyserver oder andere elektronische Wege ausgetauscht. Überprüfung der Authentizität eines Schlüssels ist deswegen von grosser Bedeutung.

Ein Schlüssel wird von GnuPG genau dann als gültig (*valid*) betrachtet, wenn er die folgenden Bedingungen erfüllt:

1. Der Schlüssel wurde von ausreichend vielen *gültigen* Schlüsseln unterschrieben, d.h. er wurde mindestens entweder von

- dem Besitzer des Schlüsselrings selbst (d.h. von einem Schlüssel mit *ultimate trust*) unterschrieben
  - mindestens  $N$  gültigen Schlüsseln, denen voll vertraut wird, unterschrieben
  - mindestens  $M$  gültigen Schlüsseln, denen geringfügig vertraut wird, unterschrieben
2. Eine Signaturkette wird nur verwendet, wenn sie ausgehend vom Besitzer des Schlüsselrings maximal die Länge  $L$  hat.

Ein Schlüssel, der von weniger voll bzw. geringfügig vertrauenswürdigen Schlüsseln als notwendig unterschrieben wurde, wird als eingeschränkt gültig (*marginally valid*) angesehen. Allerdings werden Schlüssel dieser Kategorie von GnuPG genauso wie nicht gültige Schlüssel behandelt.

GnuPG verwendet in der Standardeinstellung die Werte  $N = 1$ ,  $M = 3$  und  $L = 5$ . Damit wird *ein* Zertifikat, dass von einem Schlüssel mit vollem Vertrauen ausgestellt wurde, als ausreichend betrachtet. Für Schlüssel, denen nur geringfügig vertraut wird, ist ein einzelnes Zertifikat nicht ausreichend. Dieses muss noch durch 2 weitere solche Zertifikate bestätigt werden.

GnuPG erlaubt es einem Anwender, die Parameter  $N$ ,  $M$  und  $L$  selbst zu setzen und damit seine Sicherheitsanforderungen umzusetzen. Je höher beispielsweise die notwendige Anzahl von Signaturen, um so kleiner ist der Schaden, den eine einzelne fehlerhafte Signatur anrichten kann. Ist die maximale Pfadlänge auf einen kleinen Wert begrenzt, so ist auch die maximale Anzahl der Signaturen auf dem Pfad kleiner, die potentiell fehlerhaft sein können. Andererseits verringert sich damit die Anzahl der Signaturen (Pfade im Web of Trust), die für die Verifizierung benutzt werden können, und damit die Anzahl verifizierbarer Schlüssel. Es muss also eine Abwägung zwischen dem Sicherheitsbedürfnis des Nutzers und der praktischen Benutzbarkeit getroffen werden.

Abbildung 1.1 gibt ein Beispiel für die Berechnung der Schlüsselgültigkeit unter Verwendung der Standard-Parameter  $N = 1$ ,  $M = 3$  und  $L = 5$ . Die Schlüssel  $B$ ,  $H$  und  $K$  wurden direkt von  $A$ , dem Besitzer des Schlüsselrings, unterschrieben und sind deshalb voll gültig. Da  $L$ ,  $M$ , und  $N$  von  $K$  unterschrieben wurden und dieser über volles Vertrauen verfügt, sind sie ebenfalls voll gültig.  $O$  sowie  $J$  sind voll gültig, da sie jeweils von drei Schlüsseln mit geringfügigem Vertrauen unterschrieben wurden.  $I$  und  $P$  wurden dagegen jeweils nur von zwei Schlüsseln mit geringfügigem Vertrauen unterschrieben und sind deshalb nicht voll sondern nur eingeschränkt gültig.  $G$  wurde zwar von einem voll gültigen Schlüssel mit vollem Vertrauen unterschrieben. Allerdings überschreitet die Signaturkette zu  $A$  die maximale Länge von 5 und wird deshalb nicht betrachtet.

Ein öffentlicher Schlüssel, der anhand dieser Regeln nicht als authentisch verifiziert werden kann, kann trotzdem zur Verschlüsselung und zur Verifizierung von Signaturen verwendet werden. Allerdings warnt GnuPG in diesem Fall vor der Verwendung.

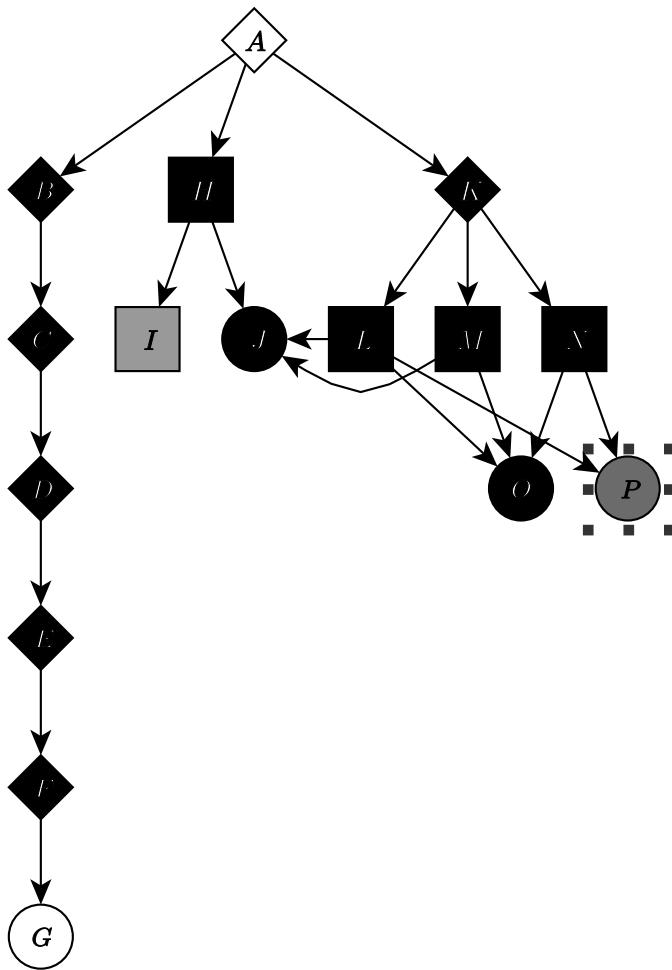


Abbildung 1.1: Beispiel für die Berechnung der Gültigkeit von Schlüsseln

#### 1.2.4 Soziale Komponente des Web of Trust

### 1.3 Der OpenPGP-Standard (RFC4880)

#### 1.3.1 Paketformat v4

#### 1.3.2 Unterschiede v3

### 1.4 Graphentheorie allgemein

### 1.5 Netzwerkanalyse

#### 1.5.1 Netzwerkstatistiken

#### 1.5.2 Communities

Seit der Arbeit von Newman wurde eine Vielzahl weiterer Methoden zur Erkennung von Communities vorgestellt. An dieser Stelle werden 3 Methoden näher beschrieben, die in dieser Arbeit verwendet werden. Einen Gesamtüberblick bietet ein Übersichtsartikel von Fortunato [Fort10].

## **1.6 Verwandte Arbeiten**

**1.6.1 Analysen des OpenPGP-Web of Trust**

**1.6.2 Community-Strukturen allgemein**

## 2. Methoden und Materialien

### 2.1 Warum eigene Software?

Das bereits in Abschnitt 1.6 erwähnte *wotsap*-Projekt berechnet täglich die Struktur des Web of Trust. Die Daten werden für eine Web-Applikation benutzt, die grundlegende Statistiken über Schlüssel berechnet und Pfade zwischen Schlüsseln graphisch darstellt. Zusätzlich werden die Daten aber auch für weitere Analysen zur Verfügung gestellt. In diesem Abschnitt wird begründet, warum für die vorliegende Arbeit nicht auf diese Daten zurückgegriffen wurde, sondern die Datenextraktion selbst vorgenommen wurde.

Ein Ziel dieser Arbeit ist es, die Struktur des Web of Trust abseits der grössten starken Zusammenhangskomponente zu untersuchen. *wotsap* berechnet allerdings nur die Struktur eben dieser Zusammenhangskomponente. Schlüssel, die nicht in dieser Komponente enthalten sind, werden nicht beachtet. *wotsap* beginnt bei mehreren sehr gut vernetzten Schlüsseln, die sicher in der MSCC liegen. Von diesen ausgehend werden die Signaturen in der Art einer Breitensuche (rückwärts) verfolgt. Aufgrund dieser Methode scheint es mit vertretbarem Aufwand nicht möglich, die Extraktion auf alle Schlüssel auszudehnen.

Der Anwendungszweck der *wotsap*-Daten ist ausschliesslich die strukturelle Analyse des Netzes. Die über die reine Struktur hinausgehenden Daten, die über Schlüssel und Signaturen gespeichert werden, sind dabei auf ein Minimum reduziert: Für Schlüssel werden ausschliesslich die KeyID und die primäre UserID gespeichert, für Signaturen der Cert level und die Schlüssel. Diese Reduktion erlaubt zwar eine sehr kompakte Speicherung der Daten, macht es aber für eine Auswertung weiterer Eigenschaften von Schlüsseln und Signaturen unbrauchbar. Das verwendete Dateiformat ist ausserdem recht unflexibel und lässt eine Speicherung weiterer Daten nur mit grösserem Aufwand zu.

Die *wotsap*-Daten beinhalten nur die zum jeweiligen Zeitpunkt gültigen Schlüssel und Signaturen. Dieser „Schnappschuss“ reicht für die strukturelle Analyse des Graphen aus. Zeitliche Entwicklungen, beispielsweise die Grösse des Datenbestandes, die Verwendung bestimmter Verschlüsselungs- und Signaturalgorithmen und die Entwicklung einzelner Komponenten können damit aber nicht nachvollzogen werden.

Die *wotsap*-Methode liefert also nicht die im Rahmen dieser Arbeit benötigten Daten. Eine Anpassung der Software würde auf eine komplette Neuimplementierung hinauslaufen. Außerdem beruht die Extraktion der Daten bei *wotsap* auf der veralteten und kaum mehr benutzten *PKS*-Keyserver-Implementierung (siehe Abschnitt 2.2.1).

Darüber hinaus ist allerdings der *wotsap*-Datensatz fehlerhaft. Diese Fehler werden sowohl durch Fehler in der Implementierung als auch durch einen fehlerhaften Datenbestand auf dem verwendeten Keyserver verursacht: Die grösste starke Zusammenhangskomponente die durch XXX berechnet wurde (MSCC-1), enthält mit dem Stand vom 02.12.2009 ca. 45100 Schlüssel, während der *wotsap*-Datensatz (MSCC-2) vom gleichen Tag nur ca. 42130 Schlüssel enthält. Die Differenz zwischen den Datensätzen ergibt einerseits, dass ca. 1000 Schlüssel in MSCC-1 fehlen, die in MSCC-2 vorhanden sind. Eine stichprobenartige Analyse von 20 Schlüsseln zeigt, dass diese Schlüssel überwiegend durch Signaturketten an die MSCC angebunden sind, die aufgrund von widerrufenen Schlüsseln oder Schlüsselteilen unterbrochen sind. Dabei treten u.a. Signaturen auf komplett widerrufenen Schlüsseln und Signaturen auf widerrufenen UserIDs auf. *wotsap* benutzt GnuPG, um die OpenPGP-Pakete eines Schlüssels zu parsen. Der Code zum Parsen der GnuPG-Ausgabe ist fehlerhaft und führt dazu, dass *wotsap* Widerruffsignaturen fälschlicherweise nicht beachtet.

Auf der anderen Seite sind ca. 3980 Schlüssel zwar in MSCC-1 vorhanden, nicht aber in MSCC-2. Um den Grund dafür zu finden, wurde für 10 zufällig ausgewählte Schlüssel aus dieser Menge eine Signaturkette (d.h. ein Pfad) zu einem Schlüssel gesucht, der sowohl in MSCC-1 als auch in MSCC-2 vorhanden ist. Ebenfalls wurde eine Kette in der anderen Richtung gesucht. Die Signaturen dieser Ketten wurden mittels GnuPG kryptographisch verifiziert, um sicherzustellen, dass sie gültig sind. Kann für beide Richtungen jeweils eine Kette erfolgreich verifiziert werden, so ist der betreffende Schlüssel per definitionem in der MSCC. Im vorliegenden Fall konnte das für alle Schlüssel der Stichprobe gezeigt werden. Der Fehler liegt also wiederum bei *wotsap*, dass diese Schlüssel fälschlicherweise ausschliesst. Als Ursache dafür ergab sich in allen betrachteten Fällen der fehlerhafte Bestand des Keyserver *wwwkeys.ch.pgp.net*, der von *wotsap* verwendet wird. Die Schlüssel wurden von *wotsap* nicht in die MSCC-2 übernommen, weil Teile der dazu notwendigen Signaturketten (komplette Schlüssel oder einzelne Signaturen) auf dem Keyserver nicht vorhanden sind. Besonders häufig traten dabei Schlüssel auf, deren Ablaufdatum durch eine neue Selbstsignatur verlängert wurde. Dieses Signaturpaket fehlte auf *wwwkeys.ch.pgp.net*, wodurch der betreffende Schlüssel fälschlicherweise als abgelaufen betrachtet wurde. Diese fehlenden Teile sind aber auf allen Keyservern des *SKS*-Verbundes vorhanden. Da die Ursache in allen untersuchten Fällen die gleiche war, kann angenommen werden, dass der Fehler systematisch ist und diesen Teil der Diskrepanz zwischen den Datensätzen vollständig erklärt. Als Ursache kommen eine mangelhafte Synchronisation zwischen *wwwkeys.ch.pgp.net* und dem *SKS*-Netzwerk sowie Fehler in der auf *wwwkeys.ch.pgp.net* verwendeten *PKS*-Version in Frage.

Die Natur der Fehler legt nahe, dass hauptsächlich solche Schlüssel fehlen bzw. fälschlich einbezogen wurden, die nur über eine sehr geringe Anzahl von redundanten Pfaden zur bzw. von der MSCC verfügen. Gäbe es mehr redundante Pfade, so hätten einzelne fehlerhafte Informationen (fehlende bzw. fälschlicherweise als gültig betrachtete Schlüssel oder Signaturen) einen geringeren Einfluss.

Die Anzahl fehlender bzw. fälschlich einbezogener Schlüssel (ca. 9% fehlend, ca. 2% fälschlich einbezogen relativ zu MSCC-1) ist so gross, dass qualitative Fehler in der Graphenstruktur zu erwarten sind. Insbesondere Aussagen über die Verteilung von Knotengraden und ähnliche Aussagen anhand dieser Daten sind mit Vorsicht zu geniessen. Eine Reihe von Arbeiten verwendet die *wotsap*-Daten als Beispiel für ein empirisches soziales bzw. Small-World-Netzwerk [BrSc06] [HeGu09] [Dell07]. Sofern die Ergebnisse dieser Arbeit auf experimentellen Resultaten aufbauen, die mit diesen Daten gewonnen wurden, sollten sie daher mit korrekten Daten überprüft werden. Der Keyserver *wwwkeys.ch.pgp.net* sollte von Anwendern nicht mehr benutzt werden.

## 2.2 Design und Implementierung

Dieser Abschnitt beschreibt die im Rahmen dieser Arbeit erstellte Software zur Extraktion und Analyse des Web of Trust. Abschnitt 2.2.1 beschreibt zunächst die Keyserver-Software *SKS*, auf die der Extraktionsteil aufbaut. Abschnitt 2.2.1 beschreibt dann die entwickelte Software selbst und begründet das Design.

### 2.2.1 Der SKS Keyserver

*SKS* (Synchronizing Key Server) löst die bis dahin verbreitetste Keyserver-Software *PKS* (Public Key Server) ab und wird inzwischen auf so gut wie allen Keyservern benutzt. Mit *pgp.mit.edu* wurde im Juli 2009 der letzte grosse Keyserver auf *SKS* umgestellt. *PKS* benutzt ein auf E-Mails basierendes Protokoll zur Synchronisation zwischen Keyservern, das ausgesprochen ineffizient ist. Außerdem kommt es mit einigen Bestandteilen des aktuellen OpenPGP-Standards wie z.B. *PhotoIDs* und mehreren Unterschlüsseln nicht zurecht. *PKS*-Keyserver können über ein Webinterface, ein E-Mail-Interface und das auf HTTP basierende HKP-Protokoll<sup>1</sup> abgefragt werden.

Im Unterschied dazu kommunizieren *SKS*-Keyserver zur Synchronisation direkt (ohne Umwege über Mailserver) miteinander. Dazu wird ein binäres „Gossip“-Protokoll benutzt, dass auf einem effizienten Algorithmus zum Abgleich von Datensätzen beruht [MiTZ03]. *SKS* unterstützt alle Bestandteile des OpenPGP-Standards.

*SKS* ist in der Sprache Objective Caml (OCaml) implementiert und benutzt die Datenbank Berkeley DB als Datenablage. Ein Datenbankeintrag besteht dabei aus einem kompletten OpenPGP-Key, d.h. einer Reihe von OpenPGP-Paketen. *SKS* ist in zwei Prozesse aufgeteilt: der *db*-Prozess beantwortet Datenbank-Abfragen für die verschiedenen Abfragemöglichkeiten (Webinterface, HKP) während der *recon*-Prozess für den Abgleich der Datenbank mit anderen Keyservern zuständig ist.

### 2.2.2 Eigene Software

Die im Rahmen dieser Arbeit entwickelte Software besteht aus zwei Teilen: Der Extraktionsteil liest Schlüssel aus der Datenbank eines Keyservers aus, parst sie, reduziert sie dabei auf die benötigten Daten und speichert sie in einer Datei ab. Die reduzierten Daten werden in einer SQL-Datenbank (PostgreSQL FIXME cite) abgelegt und können dort abgefragt werden. Der zweite Teil besteht aus einer Reihe von Werkzeugen zur Analyse dieser Daten entsprechend der Zielsetzung dieser Arbeit.

---

<sup>1</sup><http://tools.ietf.org/html/draft-shaw-openpgp-hkp-00>

### 2.2.2.1 Datenextraktion

Die Extraktion der Daten ist recht zeitaufwendig. Auf der zur Verfügung stehenden Hardware (FIXME Poolrechner Hardware) werden ca. XX Stunden benötigt. Durch die Aufteilung kann die Extraktion der Daten einmalig auf dem Keyserver vorgenommen werden, während die Daten anschliessend auf beliebigen Rechnern zur Verfügung stehen.

Der Extraktionsteil wurde direkt in die SKS-Software integriert. Dadurch ergeben sich mehrere Vorteile:

- Das Interface von SKS für den Datenbankzugriff kann wiederverwendet werden
- SKS enthält einen rudimentären OpenPGP-Parser, d.h. eine Reihe von Funktionen, die die Byte-Struktur einzelner OpenPGP-Pakete sowie die Paket-Struktur des Schlüssels parsen und die darin enthaltenen Informationen in Datenstrukturen zugänglich machen. Durch die Verwendung dieser Funktionen kann auf eine eigene Implementierung eines OpenPGP-Parsers verzichtet werden.
- Die in SKS definierten Datenstrukturen für die Auswertung von OpenPGP-Paketen und weitere Hilfsfunktionen, beispielsweise für den Umgang mit OpenPGP-Fingerprints, können verwendet und erweitert werden

Derzeit läuft der Extraktionsteil in Form eines eigenen Prozesses, der einmalig den kompletten Datenbestand ausliest. Dieser Teil könnte aber auch direkt in den *db*-Prozess integriert werden, so dass der laufende Keyserver konstant neue oder geänderte Schlüssel reduziert und in der SQL-Datenbank ablegt. Auf diese Weise könnte ein ständig aktueller Datenbestand ohne den Aufwand des vollständigen Auslesens realisiert werden. Diese Möglichkeit wurde im Rahmen dieser Arbeit nicht verfolgt, kann aber mit geringem Aufwand realisiert werden.

Da der Extraktionsprozess nur lesend auf die SKS-Datenbank zugreift, kann er die Daten auslesen, während die *recon*- und *db*-Prozesse laufen. Eine Unterbrechung des SKS-Betriebes ist nicht notwendig.

Als Sprache für die Implementierung wurde OCaml ausgewählt. Im Extraktionsteil bestand dafür aufgrund der Integration in SKS keine Wahl. Der Analyseteil wurde ebenfalls in OCaml implementiert. Da die dort verwendeten Daten ausschliesslich aus der SQL-Datenbank stammen und dort nur primitive Datentypen (Strings, Ganz- und Fliesskommazahlen) gespeichert werden, können aber für diesen Teil auch problemlos andere Sprachen verwendet werden.

Der Extraktionsteil iteriert über alle in der SKS-Datenbank enthaltenen Schlüssel. Jeder Schlüssel wird durch die in SKS enthaltenen Funktionen geparsst. Der Extraktionsteil FIXME muss dann noch

- Entscheiden, ob der Schlüssel zurückgezogen oder abgelaufen ist. Dazu werden die Selbstsignaturen auf den einzelnen UserIDs betrachtet. Falls zu einer UserID mehrere Selbstsignaturen vorliegen, wird entsprechend der Empfehlung im OpenPGP-Standard nur die aktuellste verwendet. Liegt ein Rückrufzertifikat vor oder ist der Schlüssel abgelaufen, wird das Ablauf- bzw. Rückzugsdatum gespeichert.

- Fremdsignaturen sammeln. Dazu wird jede UserID betrachtet und die darauf angebrachten Signaturen ohne Duplikate gespeichert. Hier wird ebenfalls nur die neueste Signatur verwendet. Handelt es sich bei der neuesten Signatur um eine Rückrufsignatur, wird das Datum des Rückrufs gespeichert und zusätzlich die nächstältere Signatur gesucht, auf die sich der Rückruf bezieht.
- Den Schlüssel und jede Fremdsignatur auf die benötigten Daten reduzieren. Für den Schlüssel sind dies (falls vorhanden) Rückzugs- und Ablaufdatum, die KeyID, die Liste aller UserIDs und die Information, welche davon die primäre UserID ist, das Erstellungsdatum des Schlüssels und der verwendete Public-Key-Algorithmus sowie dessen Schlüssellänge.

Eine Fremdsignatur wird reduziert auf die KeyID des Unterzeichners FIXME, den Zertifizierungslevel, das Erstellungsdatum der Signatur, falls vorhanden Ablauf- und Rückzugsdatum, der verwendete Signaturalgorithmus und der verwendete Public-Key-Algorithmus.

Grundsätzlich werden Schlüssel nur dann verworfen, wenn sie nicht parsebar, d.h. keine Abfolge gültiger OpenPGP-Pakete sind. Schlüssel, die zurückgezogen oder abgelaufen sind, werden unter Angabe des jeweiligen Datums trotzdem gespeichert. Auf diese Weise ist sichergestellt, dass der Datensatz möglichst vollständig ist. Für einen beliebigen Zeitpunkt stehen alle dann gültigen Schlüssel und Signaturen zur Verfügung. Es kann also gewissermaßen ein „Snapshot“ des Web of Trust zu einem beliebigen Zeitpunkt analysiert werden.

Sind alle Schlüssel extrahiert, werden noch solche Signaturen entfernt, deren erstellender Schlüssel im Datenbestand nicht vorhanden ist. Außerdem werden für Signaturen, die von einem Unterschlüssel erstellt wurden, die KeyID des signierenden Schlüssels auf die des „Oberschlüssels“ geändert. Dies ist notwendig, weil das hier verwendete Datenmodell keine Informationen über Unterschlüssel enthält.

Erwähnt werden muss, dass der Parse-Vorgang nur prüft, ob die Paketfolge eines Schlüssels dem OpenPGP-Standard entspricht. Es wird keinerlei kryptographische Verifizierung der Selbst- und Fremdsignaturen eines Schlüssels vorgenommen. Grundsätzlich können ohne Probleme Signaturpakete auf einem Schlüssel angebracht und diese auf einem Keyserver veröffentlicht werden, auch wenn der Ersteller nicht über das private Schlüsselmaterial für die kryptographische Signatur verfügt. Keyserver verifizieren keine Signaturen, so dass der Signaturteil des Pakets mit beliebigem Inhalt gefüllt werden kann. GnuPG und PGP verifizieren natürlich Signaturen, so dass eine solches Signaturpaket dort nicht verwendet wird und damit kein wirkliches Angriffspotential bietet. Eine Möglichkeit für den Extraktionsteil bestünde darin, die Signaturen jedes OpenPGP-Schlüssels mit GnuPG verifizieren zu lassen. Dagegen sprechen zwei Gründe: Einerseits wäre der Aufruf von GnuPG sehr zeitaufwendig. Für jeden Schlüssel müssten der Schlüssel in einen GnuPG-Schlüsselring eingefügt werden. Zusätzlich müssten noch alle Schlüssel, die den jeweiligen Schlüssel signiert haben, einzeln in der SKS-Datenbank gesucht und in den Schlüsselring eingefügt werden, um die Signaturen verifizieren zu können. Letztendlich kostet der Aufruf von GnuPG selbst Zeit. Für die Anzahl der hier verarbeiteten Schlüssel (2,6 Millionen) scheint dieser Ansatz daher ungeeignet. Sicherlich sind Schlüssel mit defekten Signaturpaketen auf den Keyservern vorhanden. Allerdings müsste deren Anzahl sehr gross sein, um signifikante Änderungen in der Struktur des Graphen und den

statistischen Auswertungen der Schlüsseleigenschaften zu erreichen. Eine grosse Zahl solcher Pakete scheint aber unwahrscheinlich, da zumindest unter Sicherheitsaspekten ein Angreifer damit keinen offensichtlichen Gewinn erreichen kann.

Die so extrahierten Daten werden auf einem beliebigen Recher in einer SQL-Datenbank (PostgresQL) abgelegt. Auf diese Weise kann darauf verzichtet werden, eigene Selektionsmechanismen zu implementieren. Stattdessen kann die gewünschte Datenmenge einfach als SQL-Abfrage formuliert werden. Auf diese Weise ergibt sich eine deutlich flexiblere Abfragemöglichkeit. Die Ablage in der Datenbank ist zwar etwas langsaamer als die Daten im Speicher zu halten. Andererseits müssen die Daten aber nicht jedesmal komplett in den Speicher geladen und dort gehalten werden. Ausserdem werden effiziente Indexstrukturen der Datenbank genutzt und müssen nicht selbst implementiert werden.

Die Tabellen sind wie folgt strukturiert: TODO

Die Zuordnung einzelner Schlüssel zu ihren starken Zusammenhangskomponenten erfolgt über die Tabelle *component\_ids*. Diese wird erst in einem separaten Schritt befüllt, nachdem die Komponentenstruktur berechnet wurde.

```
(SELECT signer, signee
  FROM sigs INNER JOIN keys ON sigs.signer = keys.keyid
 WHERE
    (keys.revoketime IS NULL OR keys.revoketime > $timestamp)
    AND (keys.exptime IS NULL OR keys.exptime > $timestamp)
    AND (sigs.revoketime IS NULL OR sigs.revoketime > $timestamp)
    AND (sigs.exptime IS NULL OR sigs.exptime > $timestamp))
INTERSECT
(SELECT signer, signee
  FROM sigs INNER JOIN keys ON sigs.signee = keys.keyid
 WHERE
    (keys.revoketime IS NULL OR keys.revoketime > $timestamp)
    AND (keys.exptime IS NULL OR keys.exptime > $timestamp)
    AND (sigs.revoketime IS NULL OR sigs.revoketime > $timestamp)
    AND (sigs.exptime IS NULL OR sigs.exptime > $timestamp))"
```

Abbildung 2.1: Abfrage aller zum Zeitpunkt \$timestamp gültigen Signaturen

Als Beispiel gibt Abb. 2.1 ein SQL-Statement an, mit dem alle gültigen (d.h. nicht zurückgezogenen oder abgelaufenen) Signaturen zu einem bestimmten Zeitpunkt abgerufen werden können.

Wie beschrieben wird in einem Durchlauf der gesamte Datenbestand extrahiert. Aufgrund der Integration in SKS wäre es auch problemlos möglich, den Extraktionsanteil nicht als eigenständigen Prozess zu implementieren, sondern den *db*-Prozess entsprechend zu erweitern, so dass jeder neue oder geänderte Schlüssel direkt in der SQL-Datenbank abgelegt wird. Auf diese Weise könnte ein jederzeit aktueller Datenbestand erhalten werden, ohne dass er ständig komplett neu berechnet werden muss.

### 2.2.2.2 Datenauswertung

Der Teil zur Datenauswertung besteht aus einer Reihe von unabhängigen Werkzeugen, die die jeweiligen Analyseaufgaben implementieren. Diese sind als Kom-

basic-properties-mpi	Verteilung von Eingangs- und Ausgangsgraden, Komponentengrößen, Nachbarschaften, Durchmesser, Radius, durchschnittliche Pfadlängen (parallelisiert mittels MPI)
betweenness-mpi	Berechnung der Betweenness-Zentralität (parallelisiert mittels MPI)
clustering-coefficient-mpi	Berechnung des Clustering Coefficient (parallelisiert mittels MPI)
export	Export des Graphen in verschiedene Dateiformate (igraph, Cytoscape)
meta-graph	Zeichnung der Struktur der starken Zusammenhangskomponenten
db-scc-information	Befüllt die SQL-Datenbank mit der Zuordnung von Knoten zu Zusammenhangskomponenten
dump-sql	Legt die extrahierten Daten einmalig in der SQL-Datenbank ab
investigate-component	Untersucht einzelne Zusammenhangskomponente in Bezug auf Herkunft der UserID's (Domains) und den Zeitraum der Entstehung der Signaturen
mscc-size	Entwicklung der Schlüsselanzahl der grössten starken Zusammenhangskomponente
simple-stats	Statistiken über die Verwendung bestimmter Schlüsseleigenschaften (Algorithmen, Schlüssellängen usw.)
time	Entwicklung der Verwendung von Signatur- und Public-Key-Algorithmen und deren Schlüssellängen

Tabelle 2.1: Foobar

mandozeilenprogramme in eigenen Prozessen realisiert. Die Aufgaben der einzelnen Werkzeuge sind in Tab. 2.1 aufgeführt.

## 2.3 Community-Analyse

In Abschnitt 1.2.4 wurden Mechanismen beschrieben, die zur Entstehung des Web of Trust beitragen. Ausgehend davon kann die Annahme getroffen werden, dass die Vernetzung wesentlich von zwei Faktoren beeinflusst wird: Teilnehmer vernetzen sich einerseits aufgrund ihrer Zugehörigkeit zu einer *sozialen Gruppe*. Dabei kann es sich um Open-Source-Projekte wie z.B. Debian, akademische Einrichtungen und Firmen handeln, aber auch um eine Gruppe von Freunden oder Bekannten. Andererseits vernetzen sich Teilnehmer auf Keysigning-Parties mit einer relativ grossen Anzahl Benutzer, die ihnen nicht unbedingt bekannt sind und mit denen sie keine starke Gruppenzugehörigkeit verbindet. Offensichtlich ist allerdings, dass diese Mechanismen sich nicht gegenseitig ausschliessen. Die bereits in 1.2.4 beschriebene Bandbreite von Keysigning-Parties reicht von Ad-hoc-Veranstaltungen mit wenigen Teilnehmern, die durchaus der selben Institution angehörig sein können, bis zu grossen, formalisierten Veranstaltungen auf Konferenzen und Messen mit etlichen Teilnehmern.

Es soll nun untersucht werden, inwiefern sich diese postulierten Entstehungsmechanismen in der Struktur des Web of Trust wiederfinden. Angenommen wird, dass sich ein hoher Anteil der Teilnehmer primär anhand dieser beiden Mechanismen vernetzen und der Anteil an Signaturen zwischen Teilnehmern, die nicht durch eine Keysigning-Party oder eine soziale Gruppe entstanden ist, deutlich geringer ist. In diesem Fall ist zu erwarten, dass sich soziale Gruppen und die Ergebnisse von Keysigning-Parties als Gruppen von Knoten im Netzwerk wiederfinden, die untereinander eine hohe Anzahl von Kanten hat, d.h. *dicht* vernetzt ist, während sich zu Knoten ausserhalb der Gruppe nur relativ wenige Kanten finden. Diese Eigenschaft entspricht exakt der in Abschnitt 1.5.2 beschriebenen Definition von *Communities*. Es erscheint als Methode deshalb sinnvoll, mit vorhandenen Methoden zur Community-Erkennung eine Zerlegung des Graphen zu berechnen und dann zu untersuchen, inwiefern sich die einzelnen so berechneten Communities entsprechend der Annahme auf soziale Gruppen bzw. Keysigning-Parties abbilden lassen. Beispielsweise könnten sich eine (oder mehrere) Communities ergeben, die von Mitgliedern des Debian-Projekts dominiert werden.

Dazu sind Kriterien nötig, um eine berechnete Community einer sozialen Gruppe, einer Keysigning-Party oder beidem zuzuordnen. Für Keysigning-Parties ist anzunehmen, dass die Signaturvorgänge zwischen den Teilnehmern einer KSP innerhalb eines eng begrenzten Zeitraums nach Stattfinden der KSP vorgenommen werden. Als einfaches Kriterium für die Erkennung einer Keysigning-Party kann also eine starke zeitliche Korrelation der Signaturvorgänge zwischen der Mehrzahl der Community-Mitglieder verwendet werden. Konkret wird hier eine Community als Produkt einer KSP betrachtet, wenn 80% der Signaturen zwischen den Mitgliedern innerhalb eines Monats vorgenommen wurden.

Die Zuordnung zu sozialen Gruppen wird dadurch erschwert, dass – abgesehen von den Schlüsseln und Signaturen selbst – keine empirischen Daten über die Gruppenzugehörigkeit vorliegen. Die einzigen Daten, die eine (primitive) Zuordnung erlauben, sind die in den UserIDs enthaltenen E-Mail-Adressen. Über die Top-Level-Domain (TLD) kann ein User einem Land zugeordnet werden, sofern es sich nicht um eine der generischen TLDs (com, org, net) handelt. Über die Second-Level-Domain kann versucht werden, einen Nutzer einer Institution zuzuordnen. Ein User, der beispielsweise über eine E-Mail-Adresse mit der Domain debian.org verfügt, ist sicherlich ein Mitglied des Debian-Projekts. Hilfreich dabei ist, dass Teilnehmer dazu tendieren, alle ihre Adressen auf ihren Schlüsseln zu vermerken, so dass viele Schlüssel mehrere UserIDs und E-Mail-Adressen haben (siehe Abschnitt 3.2). Dadurch werden die verfügbaren Informationen über Gruppenzugehörigkeiten erhöht. Adressen verbreiteter “Freemail”-Anbieter wie Gmail, GMX und Yahoo sowie Adressen von Internet Service Providern dürfen dabei natürlich nicht verwendet werden, weil ihre Verwendung nichts über eine Gruppenzugehörigkeit aussagt.

Ähnlich wie für Keysigning-Parties werden wieder einfache Schwellwerte verwendet, um eine Community einer sozialen Gruppe, also einer Domain, zuzuordnen: Eine Community kann einer Domain *zugeordnet* werden, wenn mindestens 80% der Mitglieder eine UserID mit dieser Domain haben. Außerdem wird eine Community von einer Domain *dominiert*, wenn ein erheblicher Anteil – konkret mindestens 40% – der Mitglieder eine UserID mit dieser Domain haben.

Die Schwellwerte wurden nicht anhand empirischer Daten festgelegt sondern drücken nur ein intuitives Verständnis für die überwiegende Mehrzahl der Mitglieder einer Gruppe bzw. einen erheblichen Anteil der Mitglieder einer Gruppe aus.

Wie bereits in Abschnitt 1.5.2 beschrieben, existiert – insbesondere für ungerichtete Graphen – eine Vielzahl von Methoden zur Zerlegung eines Graphen in Communities. Dabei hat sich bislang kein “bester” Algorithmus herauskristallisiert, auch wenn einige Algorithmen für eine Reihe von Benchmark-Graphen bessere Ergebnisse liefern als andere [LaFo09]. Das übliche Gütemass zum Vergleich von Community-Zerlegungen eines Graphen, dessen tatsächliche Community-Struktur nicht bekannt ist, ist der Modularity-Wert (siehe Abschnitt 2.3). Um zu vermeiden, dass eine vergleichsweise schlechte Einteilung durch einen Algorithmus die Ergebnisse verfälscht, wurden mehrere Algorithmen zur Community-Erkennung auf ungerichteten Graphen verwendet, um ihre Ergebnisse vergleichen zu können: Fast-Modularity (FM) von Newman et al., sowie der Algorithmus von Blondel et al. (LP) (siehe Abschnitt 1.5.2). Die Auswahl wurde aus folgenden Gründen getroffen:

- Fast-Modularity war einer der ersten praktikablen Algorithmen zur Community-Erkennung und wird weiterhin häufig verwendet. Allerdings liefert er in der Literatur durchgängig schlechtere Ergebnisse als moderne Algorithmen [Fort10] und wird deshalb hier nur als Vergleichsbasis verwendet.
- Der Algorithmus von Blondel et al. erzielte im Vergleich von Lancichinetti et al. [LaFo09] mit die besten Ergebnisse.

Ein weiteres Auswahlkriterium war, dass für diese Algorithmen Implementierungen öffentlich mit Sourcecode verfügbar sind. Außerdem existieren Algorithmen, die zwar für kleinere Graphen bessere Ergebnisse liefern als die hier verwendeten, aufgrund ihrer Berechnungskomplexität für grosse Graphen wie den hier vorliegenden nicht geeignet sind.

Eine Zuordnung von einer Person zu genau einer sozialen Gruppe scheint unrealistisch. Statt dessen ist davon auszugehen, dass eine Person im Allgemeinen zu mehreren Institutionen oder Gruppen zugehörig ist. Ebenso ist es möglich, dass sie sich einerseits im Kontext einer sozialen Gruppe vernetzt, andererseits aber auch an Keysigning-Parties teilnimmt. Eine solche multiple Zugehörigkeit sollte sich im Netzwerk durch eine Mitgliedschaft eines Knotens in mehreren Communities ausdrücken. Wie in 1.5.2 erwähnt, existiert eine Klasse von Algorithmen, die ein Netzwerk in *überlappende* Communities zerlegt, so dass ein Knoten Teil von mehreren Communities sein kann. Um zu untersuchen, inwiefern dieser Überlappungseffekt die Zuordnung von Knoten zu sozialen Gruppen und KSPs beeinflusst, wurde zusätzlich noch eine überlappende Zerlegung mit dem Algorithmus COPRA [Greg10], einer Verallgemeinerung von Label-Propagation auf berechnet. Dabei handelt es sich um eine Verallgemeinerung des bereits erwähnten Algorithmus Label-Propagation. COPRA erwartet einen Parameter  $v$ , der angibt, zu wie vielen Communities ein Knoten gehören kann. Um hier das Optimum bezüglich der Modularity zu finden, wurden Zerlegungen mit Werten  $v = 2, \dots, 15$  berechnet. Zum Vergleich wurde eine Zerlegung mit  $v = 1$  berechnet, die keine Überlappung erlaubt. Da COPRA nicht-deterministisch ist, wurden für jeden Wert 10 Berechnungen durchgeführt, um die Abweichung zu ermitteln.

Während Modularity die Güte einer Zerlegung nur bezogen auf die Struktur des Graphen misst, drücken die Zuordnungszahlen die Güte einer Partitionierung in Bezug auf die oben formulierte Hypothese über die Entstehung des Netzwerks aus. Wenn diese Hypothese zutrifft, ist eine Zerlegung in Bezug darauf “besser”, wenn eine grössere Anzahl von Communities einer sozialen Gruppe oder Keysigning-Party zugeordnet werden kann. Es kann nicht vorrausgesetzt werden, dass eine Zerlegung mit hoher Modularity automatisch auch eine Zerlegung mit hohen Zuordnungszahlen ist, dass sich also die real existierenden Communities direkt in der Struktur des Graphen wiederfinden.

### 2.3.1 Communities in gerichteten Graphen

Der Graph des Web of Trust ist inhärent gerichtet, da eine Signatur nur in eine Richtung gilt. Die meisten verfügbaren Methoden zur Community-Erkennung setzen im Gegensatz dazu einen ungerichteten Graphen voraus. Methoden, die auf gerichteten Graphen arbeiten, sind erst in jüngster Zeit vorgestellt worden [LeNe08] [RoBe08]. Der bis jetzt am häufigsten verwendete Ansatz für die Community-Erkennung in gerichteten Netzwerken ist es, die Richtung der Kanten zu ignorieren und den Graphen als ungerichteten Graphen zu behandeln. Auch die Arbeiten, die den Web of Trust-Graphen unter Community-Gesichtspunkten analysieren oder ihn als Benchmark für den Vergleich von Algorithmen verwenden, gehen so vor [BnPSDGA04]. Auch wenn dieses Vorgehen akzeptable Resultate liefern kann, ist doch klar, dass durch das Ignorieren der Richtung ein Informationsverlust stattfindet, der die Ergebnisse negativ beeinflussen kann. In der vorliegenden Arbeit wurde dieser übliche Ansatz des Ignorierens der Kantenrichtung verwendet, da die Methoden für ungerichtete Netzwerke besser etabliert und Implementationen dieser Algorithmen einfacher zugänglich sind. Im Fall des Web of Trust ist allerdings ein erheblicher Anteil der verbundenen Knotenpaare nur in eine Richtung verbunden, d.h. es existiert keine “Gegenkante” (siehe Abschnitt 3.1). Damit ist auch der Informationsverlust durch die Reduzierung erheblich. Es ist daher naheliegend, dass eine Community-Zerlegung des Graphen unter Berücksichtigung der Richtungsinformationen eine Zerlegung berechnen könnte, die die Struktur des Graphen besser wiedergibt und auch unter dem Gesichtspunkt der Zuteilung zu sozialen Gruppen und Keysigning-Parties bessere Resultate liefert. Um den Einfluss der Richtung zu überprüfen, wurde eine Zerlegung mit dem Algorithmus “infomap” von Rosvall et al. [RoBe08] berechnet.

# **3. Ergebnisse und Diskussion**

## **3.1 Allgemeine Merkmale des Netzwerkes**

## **3.2 Eigenschaften einzelner Schlüssel**

## **3.3 Zusammenhangskomponenten und Communities**

## **3.4 Struktur der starken Zusammenhangskomponenten**

Foobar bla bla bla.

### **3.4.1 Communities**

Die Zerlegung des gerichteten Graphen mit dem Algorithmus von Rosval et al. lieferte keine verwertbaren Ergebnisse. Zwar wurde eine Zerlegung in 2869 Partitionen berechnet. Allerdings gilt für die grosse Mehrzahl dieser Knotenmengen, dass der durch sie induzierte Teilgraph überhaupt keine Kanten hat. Nur für ca. 160 Partitionen hat der jeweils induzierte Teilgraph Kanten, in allen Fällen allerdings sehr wenige (zwischen 1 und 104 für eine Partition der Grösse 682). Dass die Knoten einer Partition in allen Fällen so gut wie keine interne Vernetzung haben und damit der Definition von Communities absolut nicht entsprechen, ist ein klarer Hinweis, dass die berechnete Zerlegung die tatsächliche modulare Struktur des Graphen nicht sinnvoll wiedergibt. Dass der Graph in der Tat eine ausgeprägte modulare Struktur hat, zeigen die anhand des ungerichteten Graphen berechneten Zerlegungen, die auch unter inhaltlichen Gesichtspunkten Sinn ergeben. Diese Struktur kann sich auch nicht erst durch die Reduzierung des gerichteten auf einen ungerichteten Graphen ergeben. Die berechnete Zerlegung mit etlichen grossen Partitionen ohne interne Vernetzung ist in keinem Fall ein sinnvolles Ergebnis eines Community-Algorithmus und spricht daher für eine fehlerhafte Berechnung. Ob diese allerdings auf Fehler

in der verwendeten Implementierung der Autoren<sup>1</sup> oder auf Fehler im Algorithmus zurückgeht, ist nicht bekannt.

Für die restlichen Methoden wurde der Graph auf einen ungerichteten Graphen reduziert. Dazu wurde jede einzelne gerichtete Kante in eine ungerichtete Kante umgewandelt. Aus dem gerichteten Graphen mit XXX Kanten ergab sich so ein ungerichteter Graph mit 295425 Kanten.

Für die COPRA-Berechnung wurden – wie in [Greg10] vorgeschlagen – Berechnungen mit unterschiedlichen Werten  $v$  durchgeführt, um den “besten” Wert im Sinne der Modularity zu ermitteln. Dabei ergaben sich mit steigender maximaler Überlappung  $v$  nur bis  $v \leq 3$  steigende Modularity-Werte, darüber hinaus fielen sie kontinuierlich ab. Deshalb wurde die Berechnung mit  $v = 3$  verwendet. Die dort berechneten Modularity-Werte hatten eine geringe Standardabweichung von 0,003. Dieses Ergebnis kommt unerwartet. In [Greg10] ergaben sich für ein PGP-Web-of-Trust-Netzwerk mit 10680 Knoten bis zu  $v = 9$  ansteigende Modularity-Werte. Das (lokale) Maximum bei geringem  $v$  für das hier verwendete Netzwerk könnte darauf hinweisen, dass seine Community-Struktur keine signifikante Überlappung aufweist. Ein weiterer Hinweis darauf ist, dass die Einführung der Überlappung mit  $v = 3$  gegenüber der nicht überlappenden Berechnung mit  $v = 1$  für die Modularity (Tabelle 3.1) keinen signifikanten Anstieg brachte. Auch die Zuordnung zu Gruppen bzw. Keysigning-Parties (Tabelle 3.2) und die Verteilung der Grösse der Communities (Abbildungen 3.2b und 3.2a) ähneln sich weitgehend. Alternativ könnte dieses Ergebnis allerdings auch in einem nicht-optimalen Verhalten des Algorithmus begründet liegen.

Für den Algorithmus von Blondel et al. zeigt sich zunächst ein deutlich höherer Modularity-Wert als für Fastmod. Dieses Ergebnis gibt also die reine Struktur des Graphen deutlich besser wieder. Wie in Abschnitt 1.5.2 beschrieben, verläuft der Algorithmus von Blondel et al. iterativ in Phasen, in denen jeweils zuerst Knoten einer benachbarten Community zugeordnet werden, wenn sich dadurch ein Modularity-Gewinn erzielen lässt, und dann die Knoten dieser so entstandenen Communities zu Knoten in einem neuen Netzwerk verschmolzen werden. Hier werden die Ergebnisse der Phasen  $l = 2$  und der letzten Phase  $l = 5$  betrachtet. Für  $l = 5$  ergab sich die höchste Modularity. Allerdings sticht hier die sehr kleine Anzahl von Communities heraus, die wiederum vergleichsweise gross sein müssen. Gegenüber dem Ergebnis der Phase 2 ergibt sich eine relativ kleine Steigerung der Modularity, die mit einem erheblichen Verlust an *Auflösung* erkauft wird<sup>2</sup>. Da der Algorithmus von Blondel et al. genauso wie Fastmod mittels einer (lokalen) Optimierung der Modularity arbeitet, könnte dieses Phänomen auf das in der Literatur beschriebene Auflösungslimit der Modularity-Funktion (bspw. [?] [GodC09]) zurückzuführen sein. Es scheint fraglich, ob die in Relation zur Grösse des Graphen sehr geringe Zahl von 186 Communities die Struktur des Graphen (in Bezug auf die inhaltliche Analyse) adäquat wiedergibt.

Abbildung 3.3 illustriert dies anhand einer Community aus der Zerlegung des Algorithmus von Blondel et al. mit  $l = 5$ , die klar abgegrenzte Untereinheiten enthält, die intuitiv wieder eigenständige Communities darstellen.

---

<sup>1</sup><http://www.tp.umu.se/~rosvall/code.html>

<sup>2</sup>Die Zerlegungen der Phasen 3 und 4 unterschieden sich nur geringfügig von der Zerlegung der Phase 5

Algorithmus	Modularity	Communities	Enthaltene Knoten
FM	0,596	552	44611
BL ( $l = 2$ )	0,701	936	44934
BL ( $l = 5$ )	0,710	186	44934
COPRA ( $v = 1$ )	(0,780)	1421	42205
COPRA ( $v = 3$ )	(0,786)	1354	—

Tabelle 3.1: Modularity-Werte, Anzahl der Communities mit mehr als 3 Knoten sowie die Anzahl der insgesamt in diesen Communities ( $>3$ ) enthaltenen Knoten für die Algorithmen Fast-Modularity (FM), Label-Propagation (LP), Blondel et al. (BL) auf Level 2 und 5 sowie COPRA. Die Modularity-Werte für COPRA entsprechen der Modularity-Definition für überlappende Zerlegungen nach [NMCM09] und können mit den anderen Werten nicht verglichen werden.

Abbildung 3.6 illustriert die begrenzte Qualität der Fast-Modularity-Zerlegung, die sich im vergleichweise niedrigen Modularity-Wert niederschlägt. In der Zeichnung des induzierten Teilgraphen einer grossen Community sind etliche dicht gezeichnete Zusammenballungen von Knoten zu sehen, die nur wenige Kanten nach aussen haben. Diese können als Community-artige Strukturen interpretiert werden. Zwar kann argumentiert werden, dass die Zeichnung die Struktur des Teilgraphen nicht notwendigerweise sinnvoll wiedergibt, dass also die dichten Teilbereiche in der Zeichnung nur Artefakte der Zeichenmethode darstellen. Allerdings zeigt Noack, dass starke Übereinstimmungen zwischen einer energieoptimalen Einbettung eines Graphen in die Ebene nach der Force-directed-Methode und einer Partitionierung eines Graphen mit optimaler Modularity bestehen [Noac09]. Es scheint daher gerechtfertigt, eine Zeichnung eines Graphen (Force-directed) mit markanten dichten Bereichen als Indiz für eine modulare Struktur dieses Graphen zu betrachten.

Aus Tabelle 3.1 geht hervor, dass sich – zumindest im Fall von Fastmod und Blondel et al. – fast alle Knoten des Graphen in einer Community wiederfinden, die mindestens die Grösse 4 hat. In Abschnitt 3.1 wurde gezeigt, dass ein erheblicher Anteil der Knoten einen sehr geringen Grad von 1 oder 2 hat. Da solche Knoten mangels Kanten nicht selbst eine dichte Vernetzung herstellen können, müssen sie Mitglied in Communities sein, in denen Knoten mit höherem Grad sowohl die interne Vernetzung der Community als auch die Vernetzung der Community mit anderen erzeugen.

COPRA scheint hingegen dazu tendieren, deutlich mehr Knoten in Communities sehr kleiner Grösse unterzubringen. Dieses Verhalten könnte dazu führen, dass die Aussagekraft der Zerlegung in Bezug auf die realen Communities geschwächt wird, wenn viele Knoten auf diese Art abgespalten werden.

Der insgesamt recht hohe Modularity-Wert weist darauf hin, dass der Graph in der Tat eine ausgeprägte modulare Struktur hat, wie dies von einem sozialen Netzwerk erwartet wird.

Aus Tabelle 3.2 geht hervor, dass für alle Zerlegungen fast alle Communities einer Top-Level-Domain zuordnenbar sind oder von einer TLD dominiert werden. Werden die generischen Top-Level-Domains (gTLD: com, org, net, info, ...) abgezogen, verbleiben im Fall von COPRA noch 519 (38%) Communities, die einer TLD (und damit einer *Country-Coded TLD* (*ccTLD*)) zugeordnet werden können und 315 (23%), die von einer ccTLD dominiert werden. Für die anderen Zerlegungen ergeben sich

Algorithmus	TLD-S	TLD-M	SLD-S	SLD-M	SIG
FM	293 (53%)	247 (44%)	56 (10%)	154 (27%)	128 (23%)
BL ( $l = 2$ )	499 (53%)	417 (45%)	41 (4%)	254 (27%)	115 (12%)
BL ( $l = 5$ )	85 (47%)	85 (47%)	15 (8%)	38 (21%)	26 (14%)
COPRA ( $v = 1$ )	824 (58%)	564 (40%)	178 (13%)	429 (30%)	572 (40%)
COPRA ( $v = 3$ )	792 (58%)	525 (38%)	187 (14%)	425 (31%)	555 (41%)

Tabelle 3.2: SLD-TLD-Zuweisung, TIME-CORR

ähnliche Werte. Damit ist immerhin etwa die Hälfte der Communities einem Land zuordnenbar. Für die von einer gTLD dominierten Communities ergeben Stichproben, dass sich die Teilnehmer der meisten dieser Communities anhand der Namen zumindest einem Sprachraum zuweisen lassen.

Dieses Ergebnis ist naheliegend. Wie in Abschnitt 2.3 dargelegt, wird davon ausgängen, dass ein wesentlicher Faktor, der das Zustandekommen von Signaturen beeinflusst, die sozialen Kontakte einer Person sind. Es ist weiterhin naheliegend, dass sich diese sozialen Kontakte unter anderem aufgrund von Sprachbarrieren und der räumlichen Nähe hauptsächlich im Rahmen eines Landes ergeben. Beispielsweise ist für eine aus Finnland stammende Person anzunehmen, dass die Mehrzahl ihrer Freunde, Bekannten, Geschäftspartner und sonstigen Kontakte wieder Finnen sind.

Zwar könnte argumentiert werden, dass das Internet die geographische bzw. nationale Beschränkung sozialer Kontakte aufhebt. Allerdings spielt die geographische Nähe eine wichtige Rolle im Signaturprozess. Die verbreitete Prozedur für das Signieren eines Schlüssels setzt ein direktes persönliches Treffen der Signierenden voraus (siehe Abschnitt 1.2.4). Es ist anzunehmen, dass die überwiegende Mehrheit der PGP-Benutzer die meiste Zeit in einem Land und damit in einem geographisch eingegrenzten Bereich verbleibt. Damit kommen für diese Mehrheit überwiegend nur Bewohner des gleichen Landes als Signaturpartner in Frage. Als Mechanismen für die internationale Vernetzung kommen dann etwa internationale Konferenzen in Frage. Nur ein sehr kleiner Teil der PGP-Benutzer dürfte die notwendige internationale Mobilität aufweisen, so dass sich seine Signaturen nicht überwiegend einem geographischen Bereich bzw. einem Land zuweisen lassen.

Es stellt sich die Frage, ob die zeitliche Korrelation der Signaturen in einer Community ein geeignetes Mittel ist, um Keysigning-Parties zu erkennen. Neben dem zeitlichen Zusammenhang der Signaturen ist ein weiteres Merkmal einer Keysigning-Party wie in Ab. 1.2.4 beschrieben, dass jeder Teilnehmer mit (fast) jedem anderem Teilnehmer Signaturen austauscht, so dass sich eine fast vollständige Vermaschung – fast eine Clique – ergibt. Eine stichprobenartige Untersuchung in den Communities zeigt, dass die meisten Communities mit zeitlicher Korrelation zumindest teilweise dieses Merkmal zeigen. Abbildung 3.4 zeigt ein Beispiel einer solchen Community. Etwa die Hälfte der Knoten ist in einer Fast-Clique enthalten, deren Knoten mit (fast) allen anderen vernetzt sind. Dieser innere Teil des Teilgraphen entspricht genau dem Bild, das als Resultat einer Keysigning-Party erwartet wird. Auch wenn dies auf die meisten der Communities mit zeitlicher Korrelation zutrifft, gibt es auch Gegenbeispiele. Abbildung 3.5 zeigt eine Community, die zwar das Kriterium der zeitlichen Korrelation erfüllt, ansonsten aber nichts mit dem erwarteten Bild einer KSP gemein hat. Allerdings erfüllt der Teilgraph trotzdem das Kriterium der Community, da die Knoten am Rand nur Signaturen zu dem zentralen Knoten haben

und damit die interne Kantendichte deutlich höher ist als die externe. Um solche Extremfälle auszuschliessen, ist als zusätzliches Kriterium für die Erkennung von KSPs ein hoher durchschnittlicher Grad der Knoten denkbar.

Insgesamt lässt sich festhalten, dass die hier verwendeten Methoden nicht geeignet sind, um den Entstehungsmechanismus

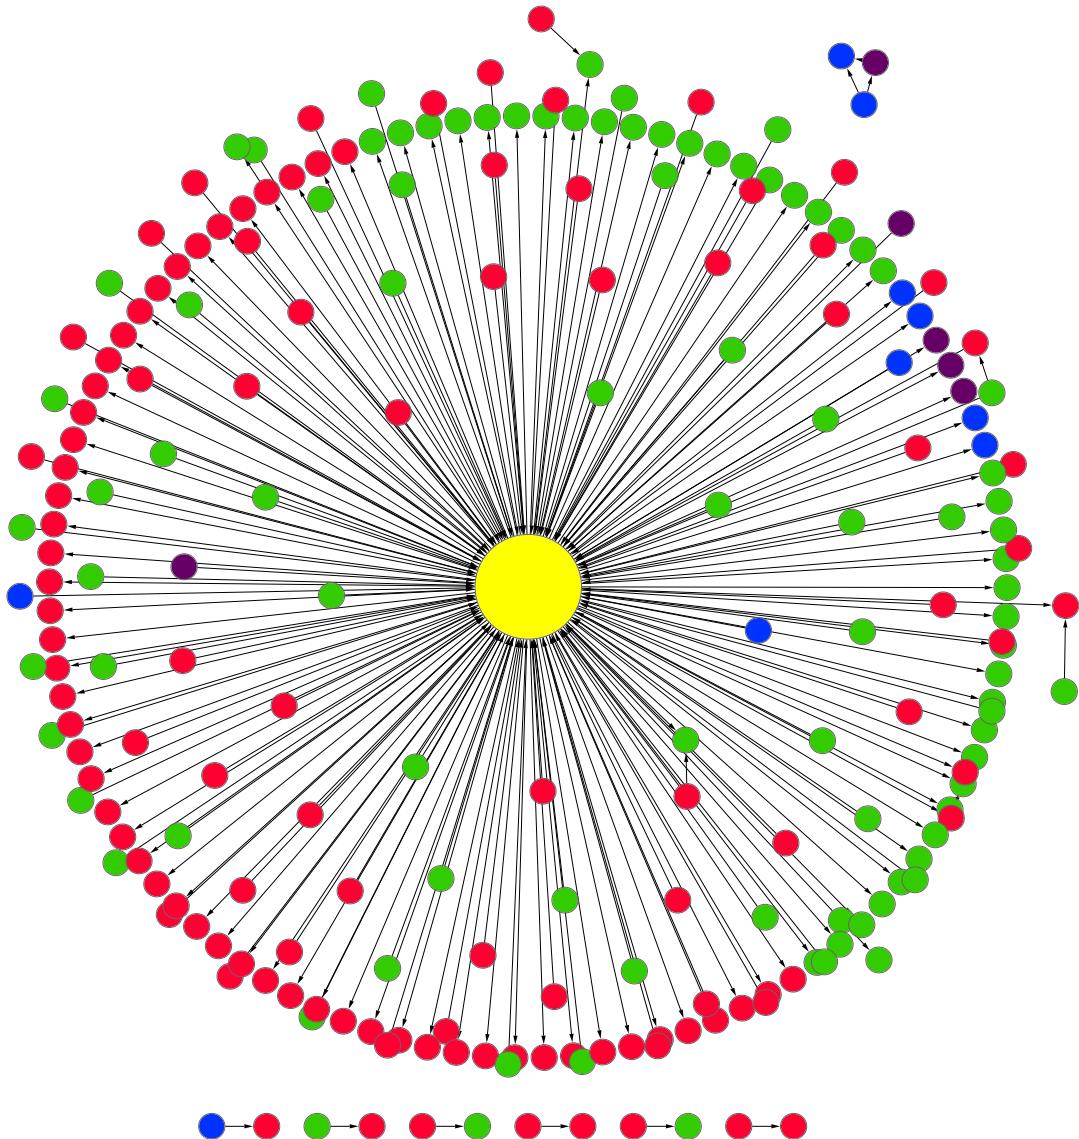


Abbildung 3.1: Struktur der starken Zusammenhangskomponenten bis zur Grösse 6 (rot = Grösse 6-10, grün = Grösse 11-20, blau = Grösse 21-30, violett = Grösse  $\geq 31$ , gelb = MSCC)

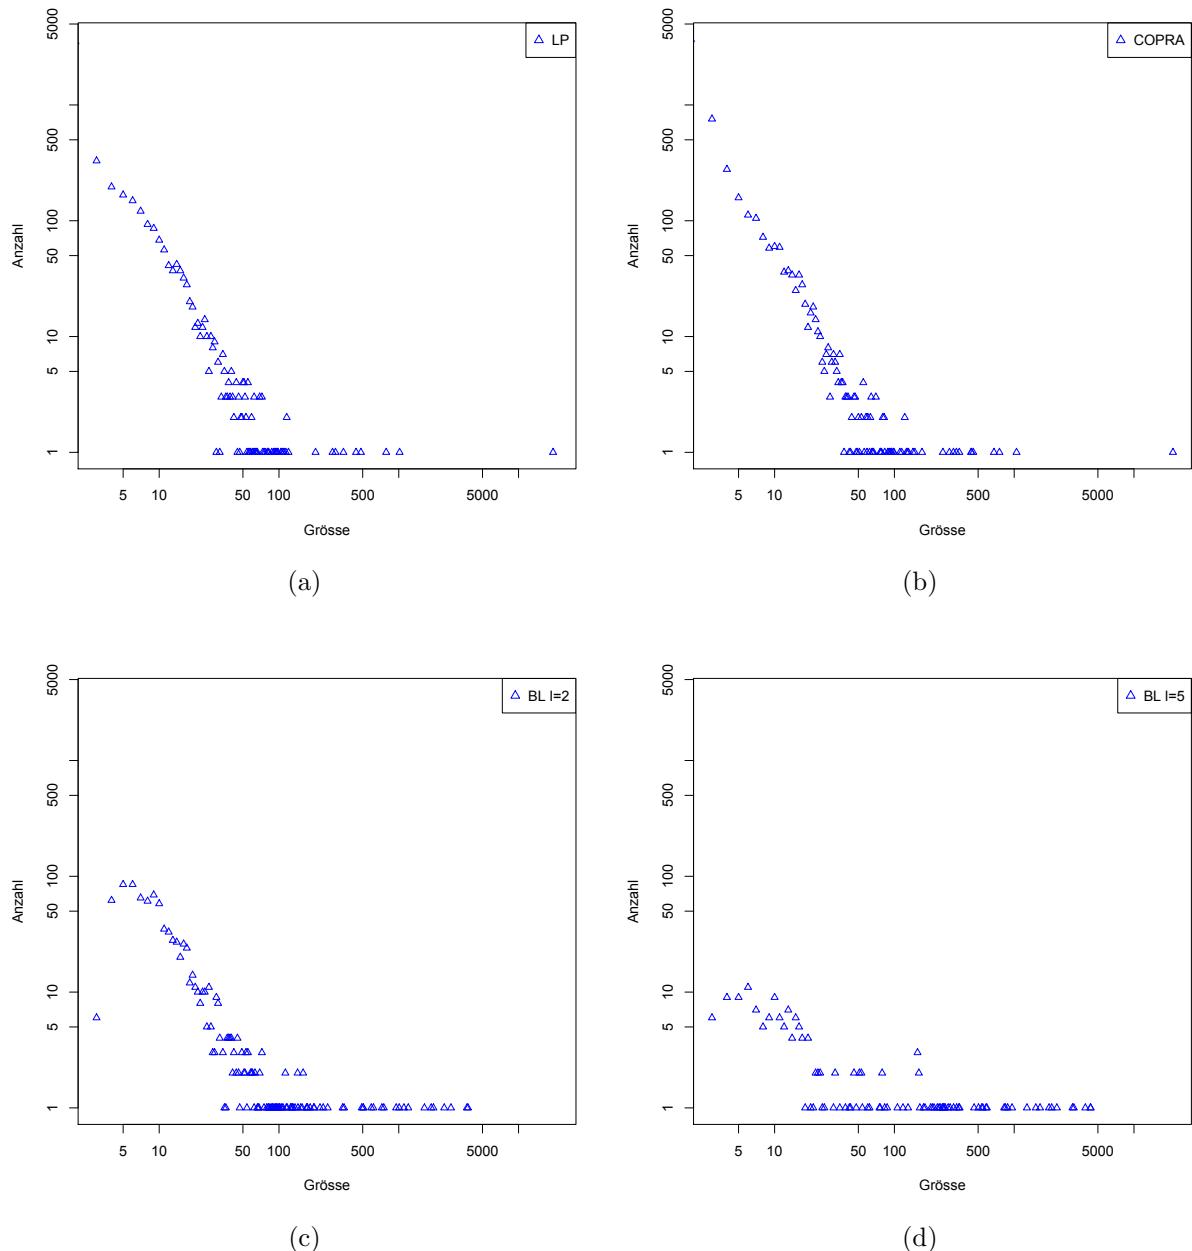


Abbildung 3.2: Größenverteilung der Communities

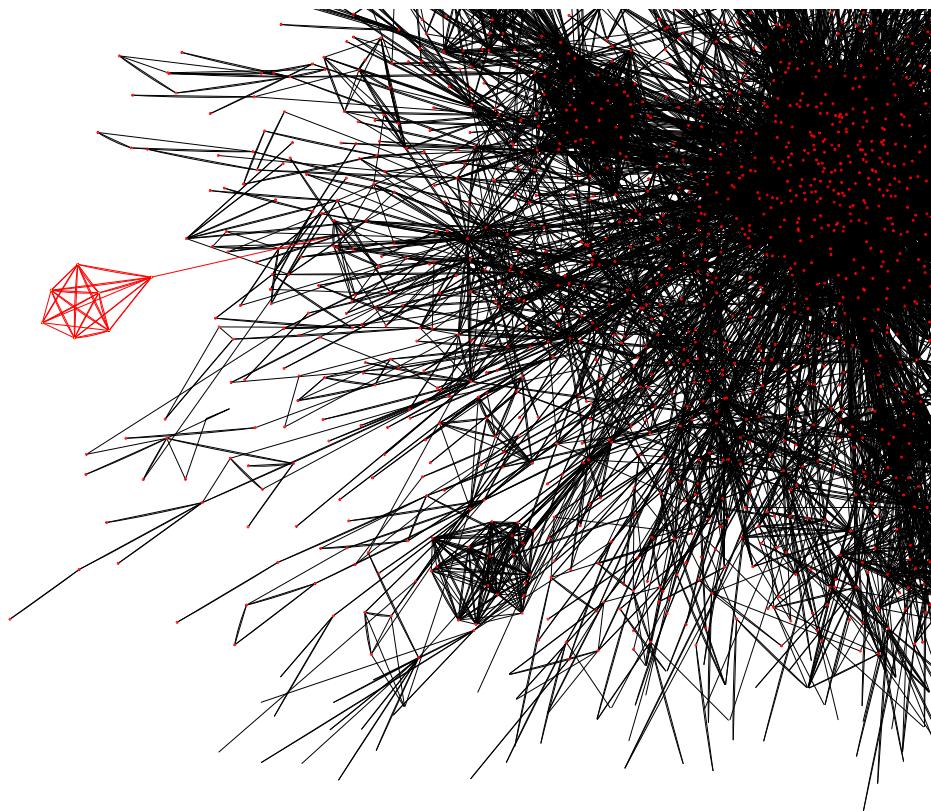


Abbildung 3.3: Community mit modularen Untereinheiten (Grösse 2271, Blondel ( $l = 5$ ), Force-directed Layout)

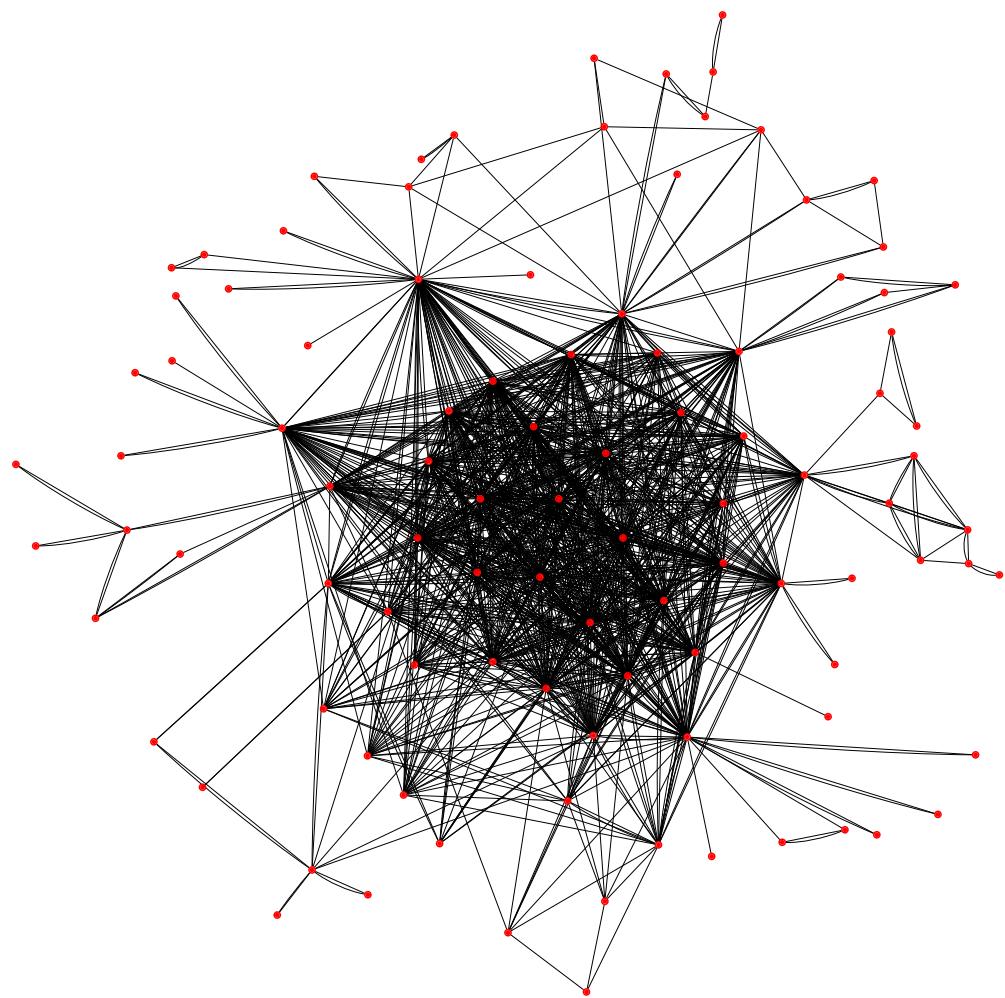


Abbildung 3.4: Community mit zeitlicher Korrelation der Signaturen (LP, 100 Knoten, 72% der Signaturen innerhalb eines Monats)

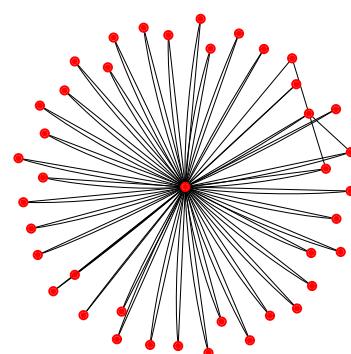


Abbildung 3.5: Community mit zeitlicher Korrelation der Signaturen (LP, 41 Knoten, 84 % der Signaturen innerhalb eines Monats)

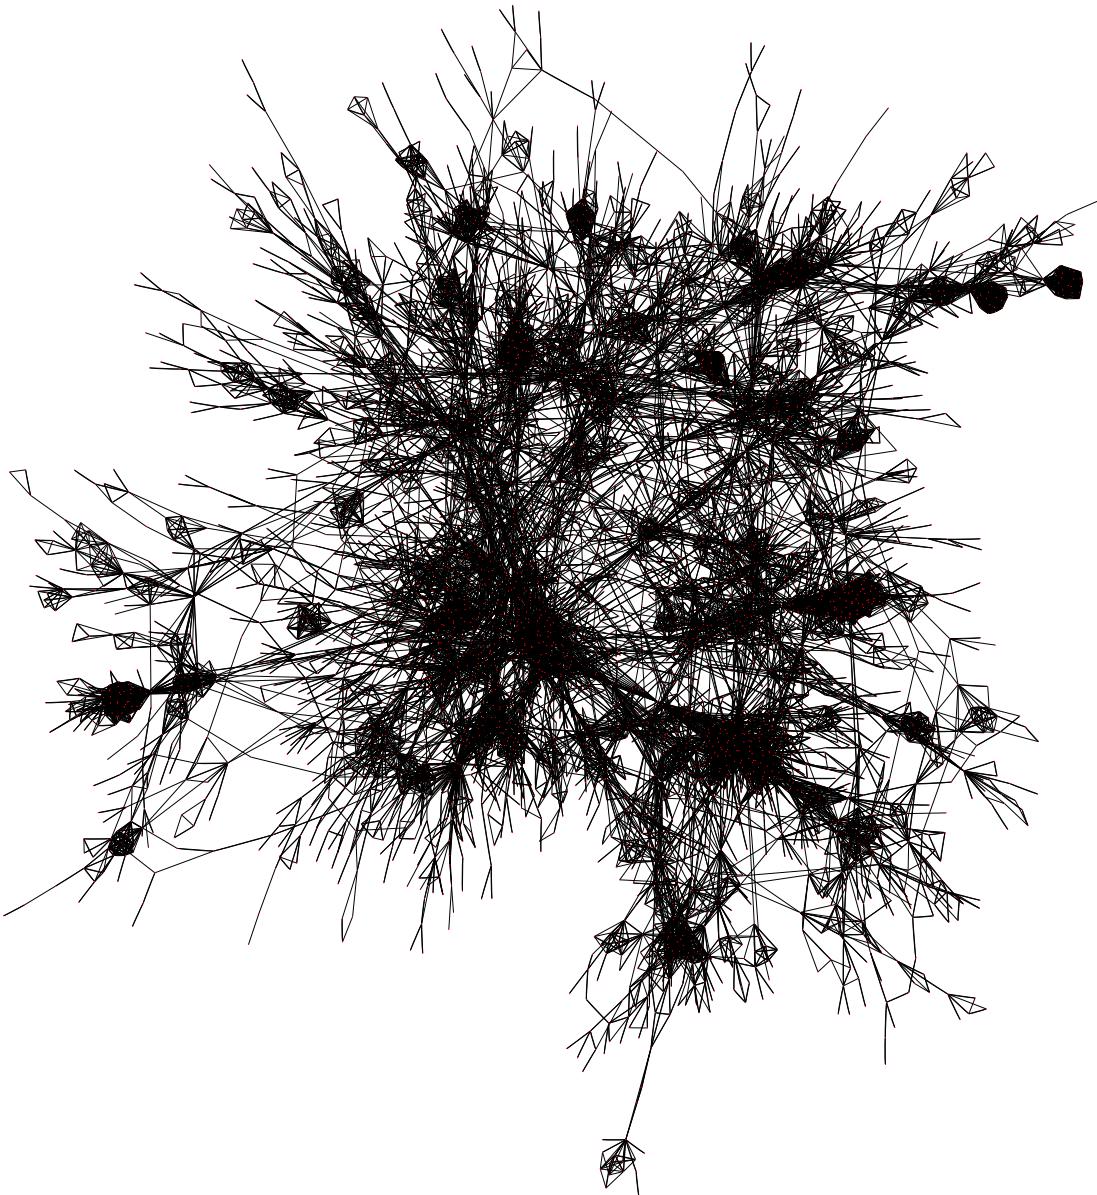


Abbildung 3.6: Grosse Community mit modularer Struktur (Berechnet mit Fast-Modularity, Force-directed layout)

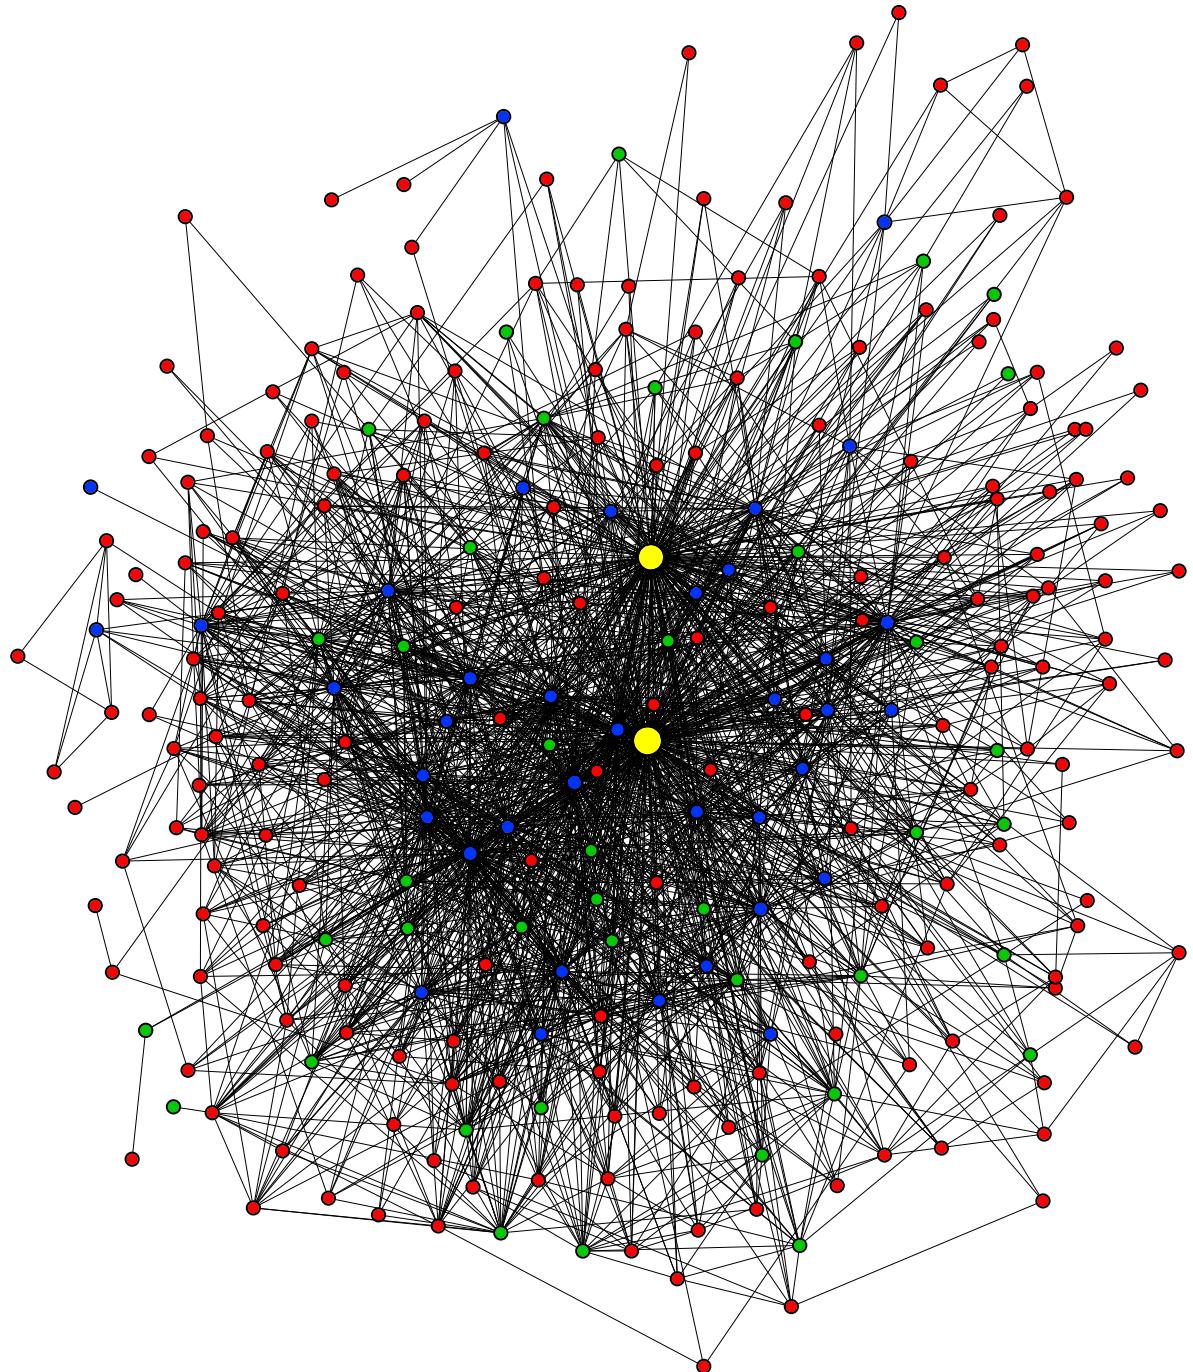


Abbildung 3.7: Struktur der Communities (Label-Propagation) (rot: Grösse < 50, grün: Grösse < 100, blau: Grösse < 1000, gelb: Grösse > 1000).

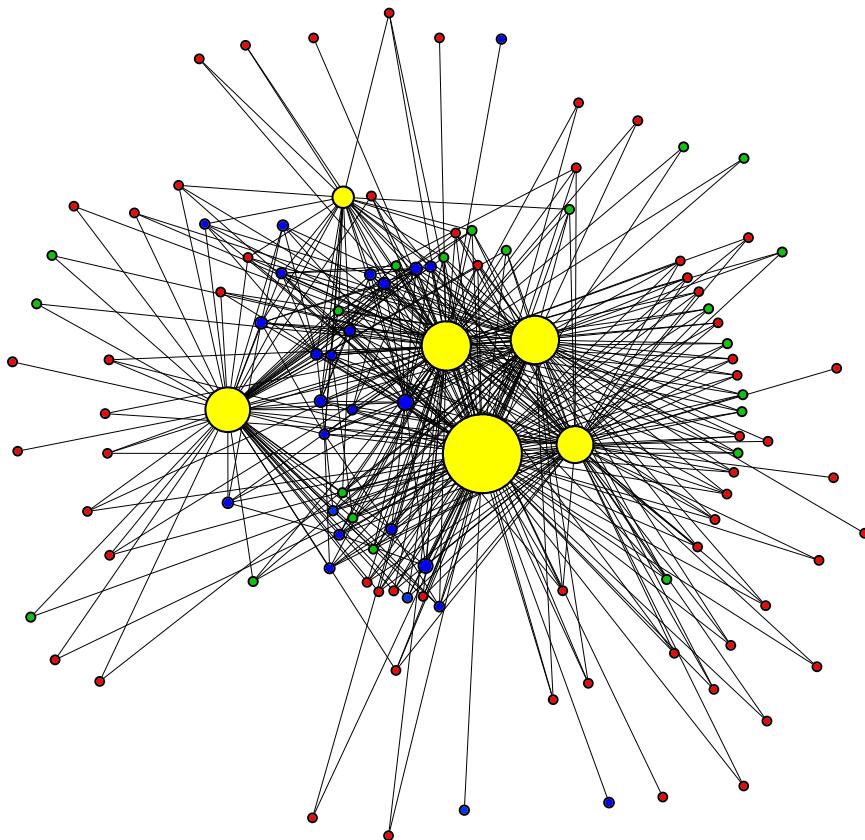


Abbildung 3.8: Struktur der Communities (Fast Modularity) (Knotenfärbung wie in Abb.3.7)

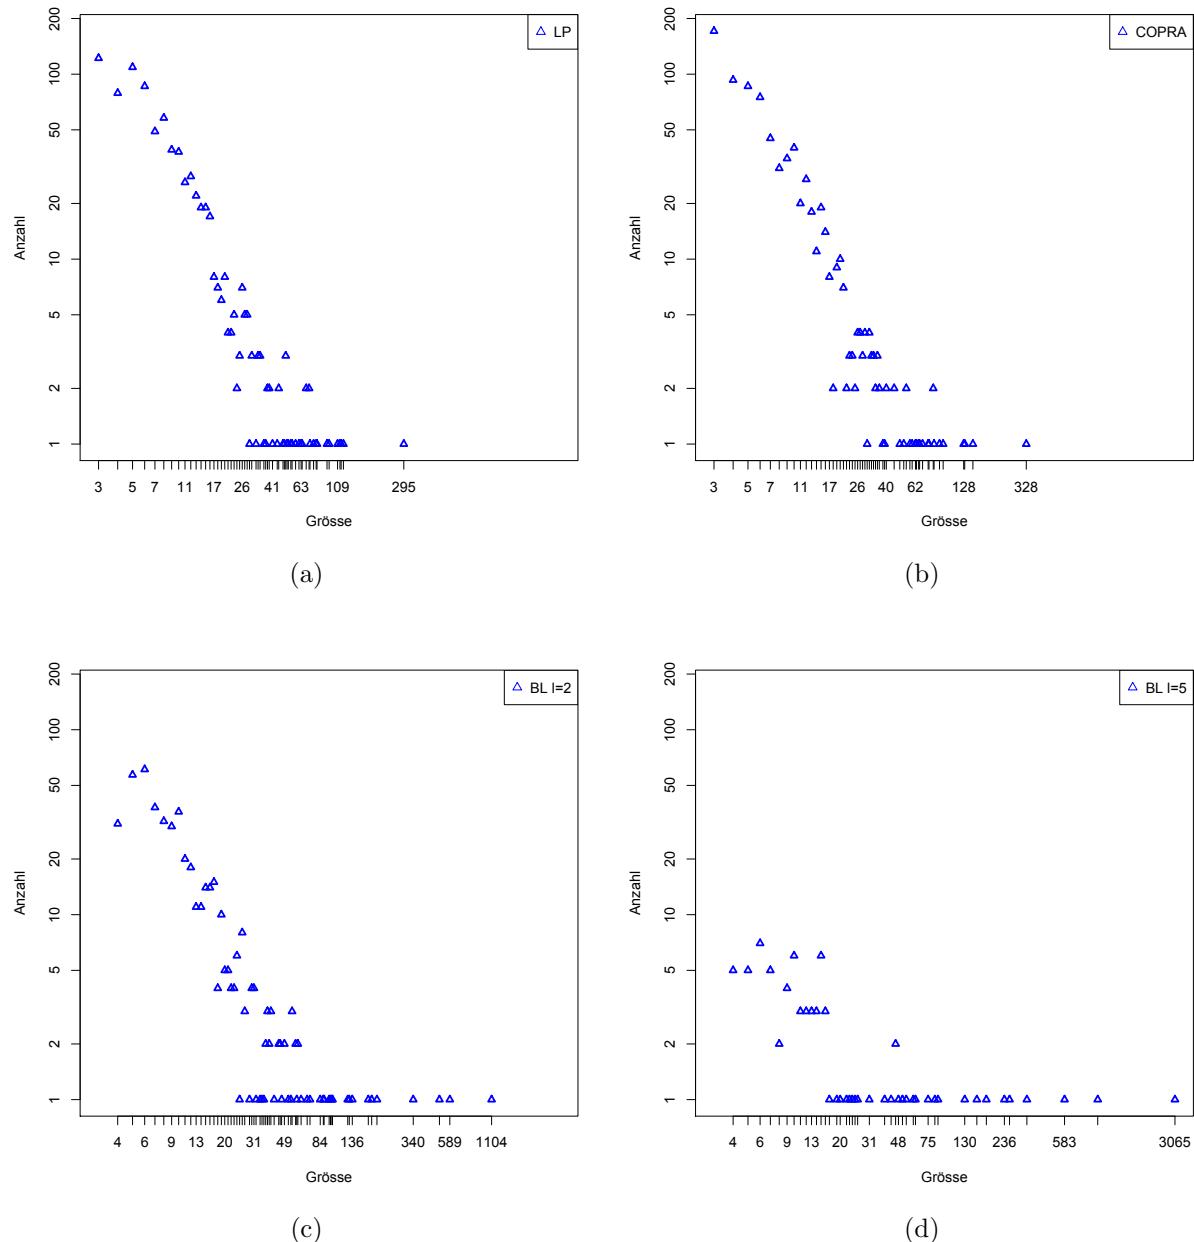


Abbildung 3.9: Zuweisung von Domains zu TLDs abhängig von der Community-Grösse

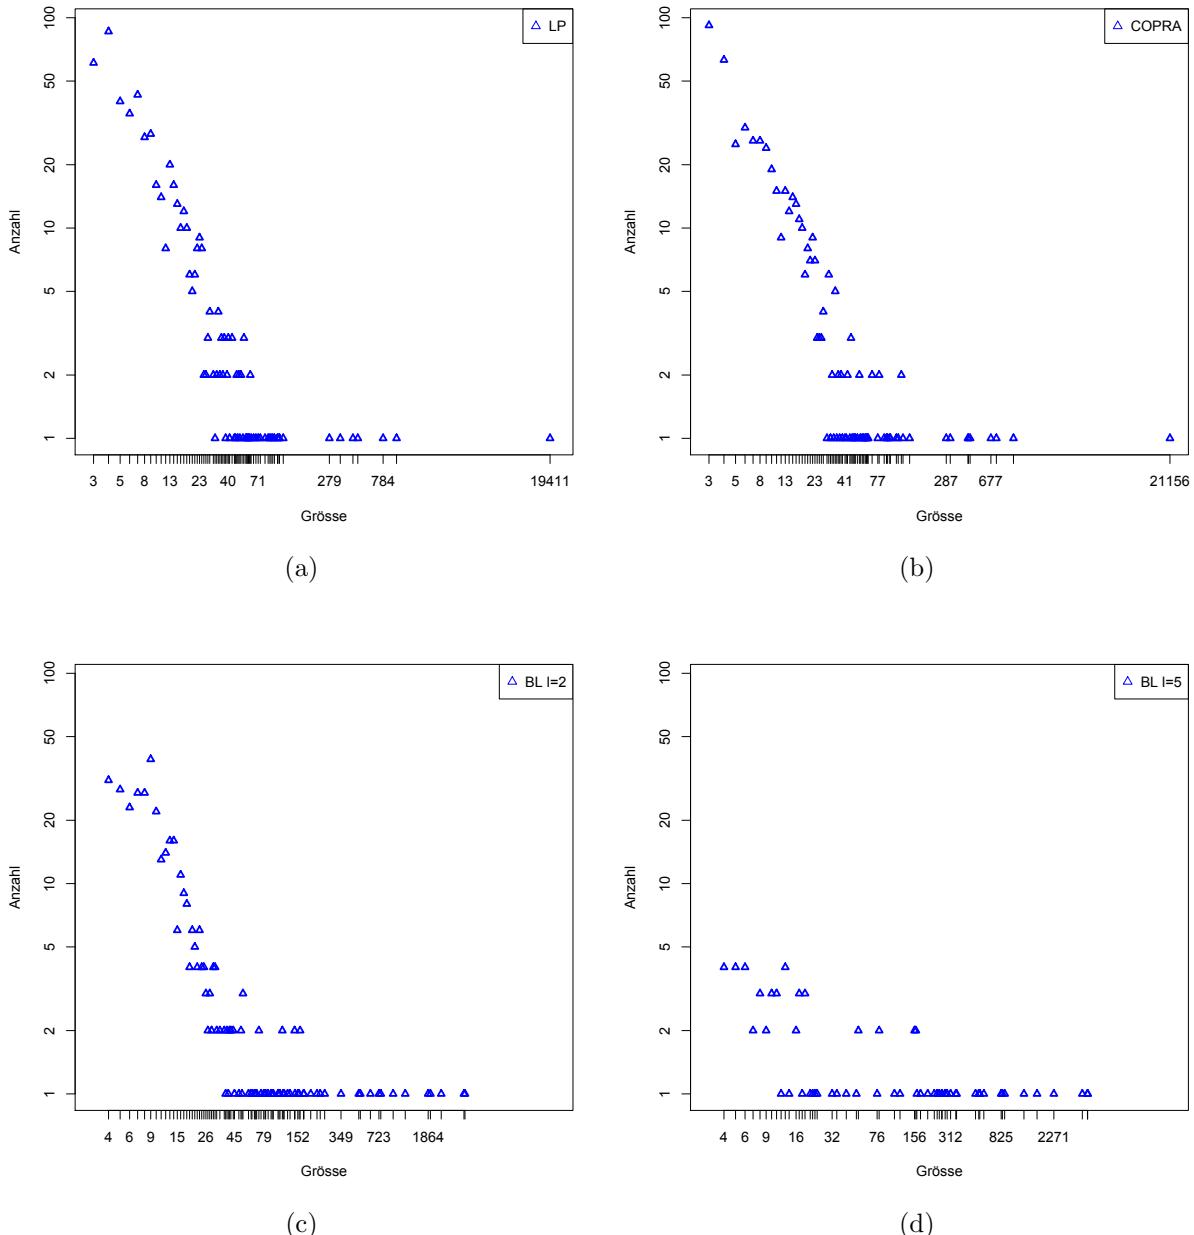


Abbildung 3.10: Verteilung der Grösse der von einer TLD dominierten Communities

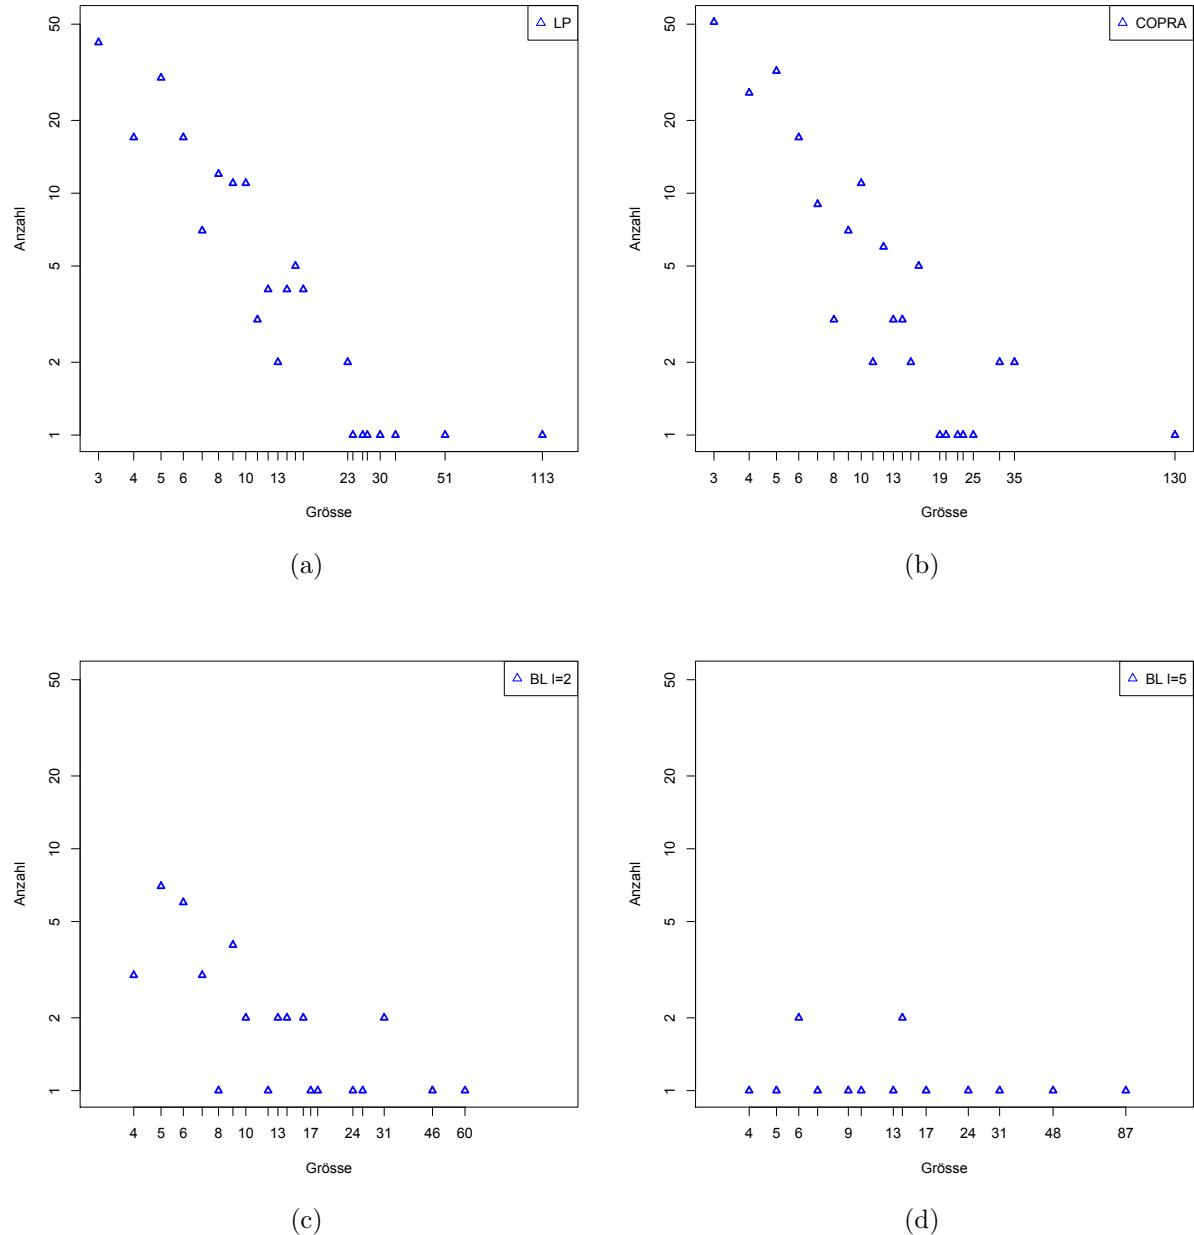


Abbildung 3.11: Zuweisung von Domains zu SLDs abhängig von der Community-Grösse

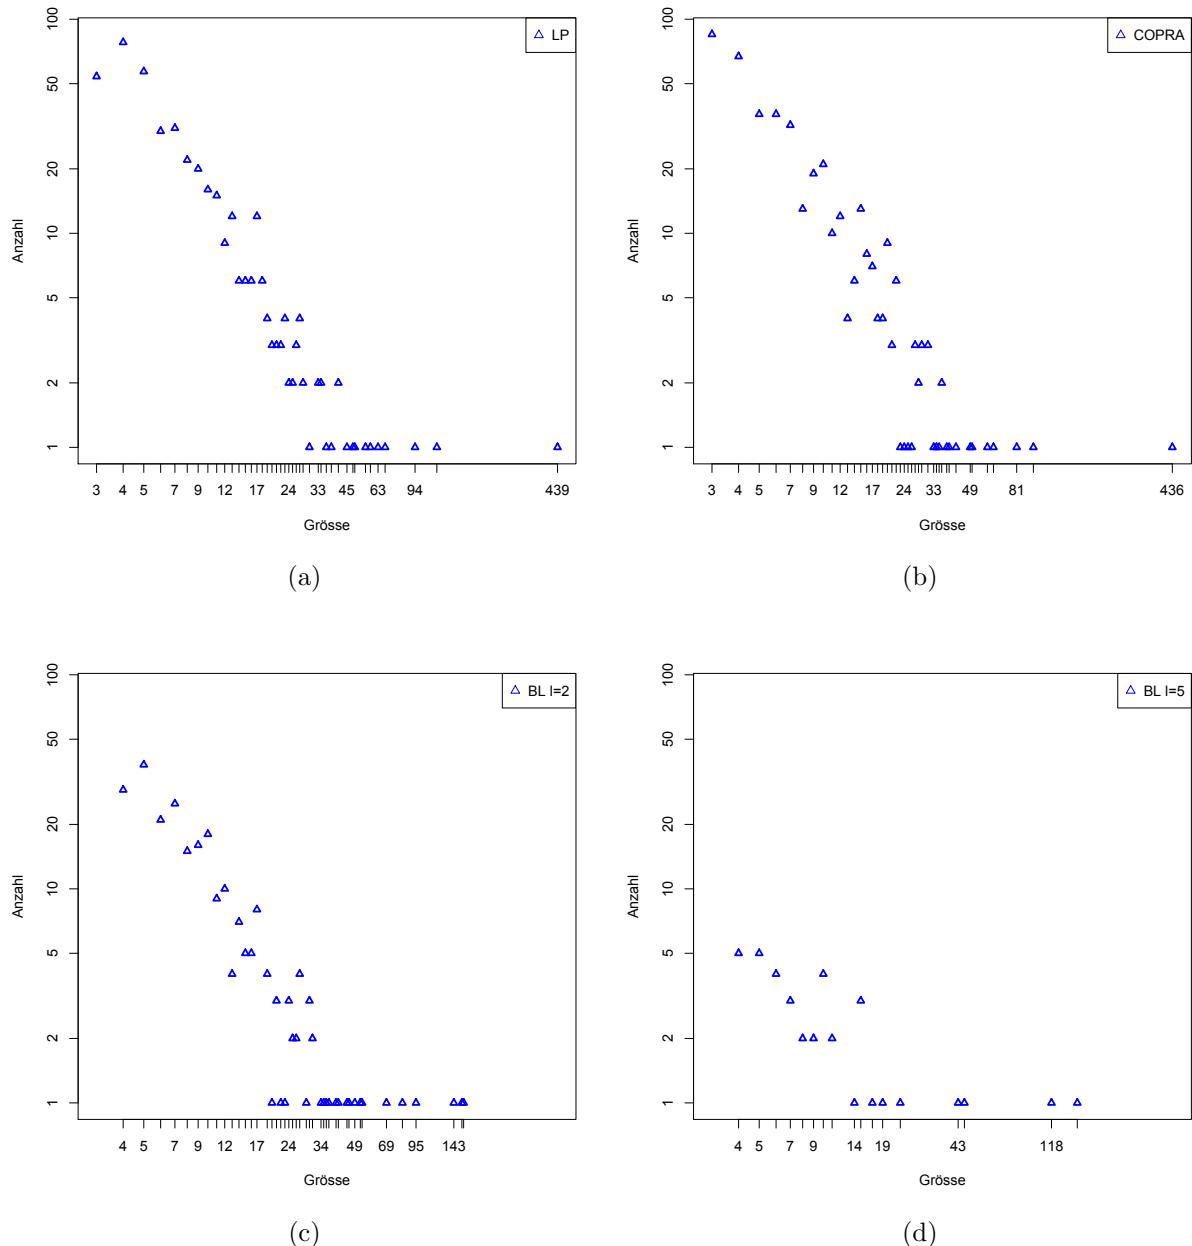


Abbildung 3.12: Verteilung der Grösse der von einer SLD dominierten Communities

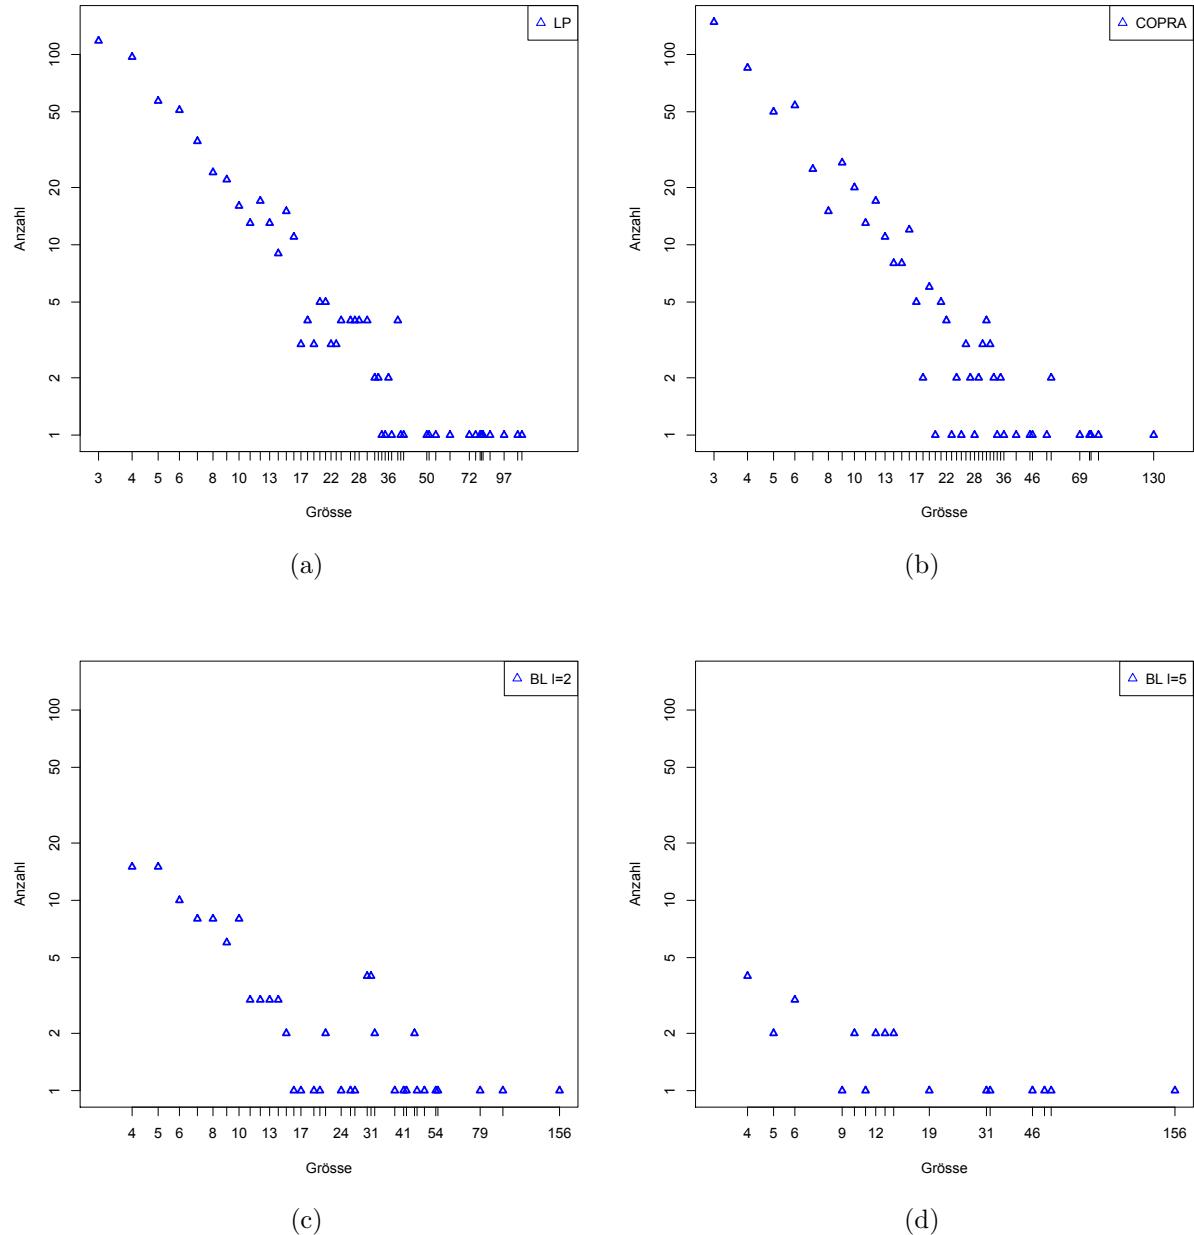


Abbildung 3.13: Verteilung der Grösse von Communities mit zeitlicher Korrelation der Signaturen



# Literaturverzeichnis

- [BnPSDGA04] M. Boguñá, R. Pastor-Satorras, A. Díaz-Guilera und A. Arenas. Models of social networks based on social distance attachment. *Phys. Rev. E* 70(5), Nov 2004, S. 056122.
- [BrSc06] D. Brondsema und A. Schamp. Konfidi: Trust Networks Using PGP and RDF. In T. Finin, L. Kagel und D. Olmedilla (Hrsg.), *MTW*, Band 190 der *CEUR Workshop Proceedings*. CEUR-WS.org, 2006.
- [Dell07] M. Dell'Amico. Mapping Small Worlds. In M. Hauswirth, A. Wierzbicki, K. Wehrle, A. Montresor und N. Shahmehri (Hrsg.), *Peer-to-Peer Computing*. IEEE Computer Society, 2007, S. 219–228.
- [Fort10] S. Fortunato. Community detection in graphs. *Physics Reports* 486(3-5), 2010, S. 75 – 174.
- [GodC09] B. H. Good, Y.-A. de Montjoye und A. Clauset. The performance of modularity maximization in practical contexts, 2009.
- [Greg10] S. Gregory. Finding overlapping communities in networks by label propagation. Arxiv preprint arXiv:0910.5516, February 2010.
- [HeGu09] J. Heikkilä und A. Gurto. Filtering SPAM in P2PSIP Communities with Web of Trust. In A. U. Schmidt und S. Lian (Hrsg.), *MobiSec*, Band 17 der *Lecture Notes of the Institute for Computer Sciences, Social Informatics and Telecommunications Engineering*. Springer, 2009, S. 110–121.
- [LaFo09] A. Lancichinetti und S. Fortunato. Community detection algorithms: A comparative analysis. *Phys. Rev. E* 80(5), Nov 2009, S. 056117.
- [LeNe08] E. A. Leicht und M. E. J. Newman. Community Structure in Directed Networks. *Phys. Rev. Lett.* 100(11), Mar 2008, S. 118703.
- [MiTZ03] Y. Minsky, A. Trachtenberg und R. Zippel. Set reconciliation with nearly optimal communication complexity. *IEEE Transactions on Information Theory* 49(9), 2003, S. 2213–2218.
- [NMCM09] V. Nicosia, G. Mangioni, V. Carchiolo und M. Malgeri. Extending the definition of modularity to directed graphs with overlapping communities. *Journal of Statistical Mechanics: Theory and Experiment* 2009(03), 2009, S. P03024.

- [Noac09] A. Noack. Modularity clustering is force-directed layout. *Phys. Rev. E* 79(2), Feb 2009, S. 026102.
- [RoBe08] M. Rosvall und C. T. Bergstrom. Maps of random walks on complex networks reveal community structure. *Proceedings of the National Academy of Sciences* 105(4), 2008, S. 1118–1123.